

第一章 误差与误差分析

第一节 误差的基本概念

1.1.1 误差及其来源

误差和误差界

对于一个确定的数 x ，假设它的计算值为 $\tilde{x}$ ，则其误差为

误差和误差界

对于一个确定的数 x ，假设它的计算值为 $\tilde{x}$ ，则其误差为

$$e = \tilde{x} - x. \quad (1.1.1)$$

误差和误差界

对于一个确定的数 x ，假设它的计算值为 $\tilde{x}$ ，则其误差为

$$e = \tilde{x} - x. \quad (1.1.1)$$

$|e|$ 越小，说明 $\tilde{x}$ 越精确。

误差和误差界

对于一个确定的数 x ，假设它的计算值为 $\tilde{x}$ ，则其误差为

$$e = \tilde{x} - x. \quad (1.1.1)$$

$|e|$ 越小，说明 $\tilde{x}$ 越精确。可是，在几乎所有情况下， x 无法得到（否则我们还要 $\tilde{x}$ 干嘛？），

误差和误差界

对于一个确定的数 x ，假设它的计算值为 $\tilde{x}$ ，则其误差为

$$e = \tilde{x} - x. \quad (1.1.1)$$

$|e|$ 越小，说明 $\tilde{x}$ 越精确。可是，在几乎所有情况下， x 无法得到（否则我们还要 $\tilde{x}$ 干嘛？），当然， e 也无法得到。

误差和误差界

对于一个确定的数 x ，假设它的计算值为 $\tilde{x}$ ，则其误差为

$$e = \tilde{x} - x. \quad (1.1.1)$$

$|e|$ 越小，说明 $\tilde{x}$ 越精确。可是，在几乎所有情况下， x 无法得到（否则我们还要 $\tilde{x}$ 干嘛？），当然， e 也无法得到。

但通常我们感兴趣的是 $|e|$ 不会超过多少，也就是误差的界，记为 ε ；有时，也对误差的符号感兴趣。这个误差界一般可以通过理论分析得到。

相对误差

假设有两个值: $x_1 = 10^{10}$, $x_2 = 1$. 如果它们的计算值误差都不超过10, 那么显然 x_1 的估计值 $\tilde{x}_1$ 对于 x_1 是有效的, 而 $\tilde{x}_2$ 则是无效的。为什么会这样呢?

相对误差

假设有两个值: $x_1 = 10^{10}$, $x_2 = 1$. 如果它们的计算值误差都不超过10, 那么显然 x_1 的估计值 $\tilde{x}_1$ 对于 x_1 是有效的, 而 $\tilde{x}_2$ 则是无效的。为什么会这样呢? 因为后者的相对误差比前者大很多!

相对误差

假设有两个值: $x_1 = 10^{10}$, $x_2 = 1$. 如果它们的计算值误差都不超过10, 那么显然 x_1 的估计值 $\tilde{x}_1$ 对于 x_1 是有效的, 而 $\tilde{x}_2$ 则是无效的。为什么会这样呢? 因为后者的相对误差比前者大很多!

我们定义

$$e_r = \frac{|\tilde{x} - x|}{|x|} = \frac{|e|}{|x|} \quad (1.1.2)$$

为 $\tilde{x}$ 的相对误差。

相对误差

假设有两个值： $x_1 = 10^{10}$, $x_2 = 1$. 如果它们的计算值误差都不超过10, 那么显然 x_1 的估计值 $\tilde{x}_1$ 对于 x_1 是有效的, 而 $\tilde{x}_2$ 则是无效的。为什么会这样呢? 因为后者的相对误差比前者大很多!

我们定义

$$e_r = \frac{|\tilde{x} - x|}{|x|} = \frac{|e|}{|x|} \quad (1.1.2)$$

为 $\tilde{x}$ 的相对误差。

对于 x_1 , $e_r \leq 10^{-9}$; 而对于 x_2 , $e_r \leq 10$. 因此, 即使两者绝对误差相同, 但是相对误差相差很多。

相对误差界

同样，由于得不到 x ，我们用

$$\tilde{e}_r = \frac{|\tilde{x} - x|}{|\tilde{x}|} \leq \frac{\varepsilon}{|\tilde{x}|} \stackrel{\text{def}}{=} \varepsilon_r$$

来替代 e_r 。当然实际中能得到的也只是 $\tilde{e}_r$ 的一个上界，称为相对误差界，记为 ε_r 。

相对误差界

同样，由于得不到 x ，我们用

$$\tilde{e}_r = \frac{|\tilde{x} - x|}{|\tilde{x}|} \leq \frac{\varepsilon}{|\tilde{x}|} \stackrel{\text{def}}{=} \varepsilon_r$$

来替代 e_r 。当然实际中能得到的也只是 $\tilde{e}_r$ 的一个上界，称为相对误差界，记为 ε_r 。

例如，对于 $f(x) \in C[a, b]$ 满足 $f(a) \cdot f(b) < 0$ 。如果用 $c = \frac{a+b}{2}$ 来近似替代 f 在 $[a, b]$ 上的零点 x_0 ，则误差界和相对误差界分别为

$$|c - x_0| < \frac{b - a}{2} = \varepsilon, \quad \frac{|c - x_0|}{|c|} < \frac{b - a}{|b + a|} = \varepsilon_r, \quad c \neq 0.$$

误差的来源

我们使用一个简单的例子来说明误差的几种不同来源。

误差的来源

我们使用一个简单的例子来说明误差的几种不同来源。

一个弹性系数为 k 的弹簧，其上端固定，下端悬挂一个质量为 m 的物体。忽略空气阻力，其运动方程为

$$m \frac{d^2 x}{dt^2} + kx = f(t), \quad x(0) = x_0, \quad \left. \frac{dx}{dt} \right|_{t=0} = v_0,$$

其中， x 为物体离开平衡位置的距离， $\frac{dx}{dt}$ 为速度， $\frac{d^2 x}{dt^2}$ 为加速度， $f(t)$ 为 t 时刻作用在物体上的外力。

误差的来源

我们使用一个简单的例子来说明误差的几种不同来源。

一个弹性系数为 k 的弹簧，其上端固定，下端悬挂一个质量为 m 的物体。忽略空气阻力，其运动方程为

$$m \frac{d^2 x}{dt^2} + kx = f(t), \quad x(0) = x_0, \quad \left. \frac{dx}{dt} \right|_{t=0} = v_0,$$

其中， x 为物体离开平衡位置的距离， $\frac{dx}{dt}$ 为速度， $\frac{d^2 x}{dt^2}$ 为加速度， $f(t)$ 为 t 时刻作用在物体上的外力。

用计算机求解该问题得到的近似解 $\tilde{x}(t)$ 与精确解 $x(t)$ 之间一定会有误差。引起误差的来源包括：

误差的来源...

- ① 测量误差：物体质量 m 和弹性系数 k 是测量值，带有误差；

误差的来源...

- ① 测量误差：物体质量 m 和弹性系数 k 是测量值，带有误差；
- ② 模型误差：由于忽略了空气阻力，模型本身与实际情况有偏差，即使考虑了空气阻力，阻力项如何表达也是问题；

误差的来源...

- ① 测量误差：物体质量 m 和弹性系数 k 是测量值，带有误差；
- ② 模型误差：由于忽略了空气阻力，模型本身与实际情况有偏差，即使考虑了空气阻力，阻力项如何表达也是问题；
- ③ 离散误差（截断误差）：在用离散方法求解该常微分方程时，由于计算机只能求解有限问题，故在离散时只能截断有限项；

误差的来源...

- ① 测量误差：物体质量 m 和弹性系数 k 是测量值，带有误差；
- ② 模型误差：由于忽略了空气阻力，模型本身与实际情况有偏差，即使考虑了空气阻力，阻力项如何表达也是问题；
- ③ 离散误差（截断误差）：在用离散方法求解该常微分方程时，由于计算机只能求解有限问题，故在离散时只能截断有限项；
- ④ 舍入误差：计算机进行浮点运算产生的误差。

误差的来源...

- ① 测量误差：物体质量 m 和弹性系数 k 是测量值，带有误差；
- ② 模型误差：由于忽略了空气阻力，模型本身与实际情况有偏差，即使考虑了空气阻力，阻力项如何表达也是问题；
- ③ 离散误差（截断误差）：在用离散方法求解该常微分方程时，由于计算机只能求解有限问题，故在离散时只能截断有限项；
- ④ 舍入误差：计算机进行浮点运算产生的误差。

本课程主要结合具体算法讨论截断误差和舍入误差。

第一章 误差与误差分析

第一节 误差的基本概念

1.1.2 误差与有效数字

有效数字

当准确值 x 有多位数时，常按四舍五入原则得到 x 的前几位近似值 $\tilde{x}$.

如： $x = \pi = 3.1415926 \cdots$.

有效数字

当准确值 x 有多位数时，常按四舍五入原则得到 x 的前几位近似值 $\tilde{x}$.

如： $x = \pi = 3.1415926 \cdots$.

- 若取前3位，则 $\tilde{x}_3 = 3.14$, 其绝对误差限 $\varepsilon_3 \leq 0.0015926 \cdots \leq 0.002 \leq 0.5 \times 10^{-2}$;

有效数字

当准确值 x 有多位数时，常按四舍五入原则得到 x 的前几位近似值 $\tilde{x}$.

如： $x = \pi = 3.1415926 \cdots$.

- 若取前3位，则 $\tilde{x}_3 = 3.14$, 其绝对误差限 $\varepsilon_3 \leq 0.0015926 \cdots \leq 0.002 \leq 0.5 \times 10^{-2}$;
- 若取前5位，则 $\tilde{x}_5 = 3.1416$, 其绝对误差限 $\varepsilon_5 \leq 0.000008 \leq 0.5 \times 10^{-4}$.

有效数字

当准确值 x 有多位数时，常按四舍五入原则得到 x 的前几位近似值 $\tilde{x}$.

如： $x = \pi = 3.1415926 \cdots$.

- 若取前3位，则 $\tilde{x}_3 = 3.14$, 其绝对误差限 $\varepsilon_3 \leq 0.0015926 \cdots \leq 0.002 \leq 0.5 \times 10^{-2}$;
- 若取前5位，则 $\tilde{x}_5 = 3.1416$, 其绝对误差限 $\varepsilon_5 \leq 0.000008 \leq 0.5 \times 10^{-4}$.

它们的误差都不会超过四舍五入近似时，末位数字的半个单位。因此我们有以下的关于有效数字的定义：

有效数字...

定义2 有效数字定义

若近似值 $\tilde{x}$ 的误差限是某一位的半个单位，该位到 $\tilde{x}$ 的第一位非零数字共有 n 位，就说 $\tilde{x}$ 有 n 位有效数字。它可表示为

$$\tilde{x} = \pm 10^m \times (a_1 + a_2 \times 10^{-1} + \cdots + a_n \times 10^{-(n-1)}), \quad (1.2.1)$$

其中， $a_i (i = 1, 2, \cdots, n)$ 是0到9中的一个数字， $a_1 \neq 0$, m 为整数，且

$$|x - \tilde{x}| \leq \frac{1}{2} \times 10^{m-n+1}. \quad (1.2.2)$$

举例

例1. 3.142, 3.141, $\frac{22}{7}$ 分别作为 π 的近似值, 各有几位有效数字?

举例

例1. 3.142, 3.141, $\frac{22}{7}$ 分别作为 π 的近似值, 各有几位有效数字?

【解】 $\pi = 3.14159265 \cdots$. 记 $x_1 = 3.142, x_2 = 3.141, x_3 = \frac{22}{7}$. 本题 $m = 0$

举例

例1. 3.142, 3.141, $\frac{22}{7}$ 分别作为 π 的近似值, 各有几位有效数字?

【解】 $\pi = 3.14159265 \cdots$. 记 $x_1 = 3.142, x_2 = 3.141, x_3 = \frac{22}{7}$. 本题 $m = 0$

- $\pi - x_1 = 3.14159265 \cdots - 3.142 = -0.00040 \cdots \Rightarrow |\pi - x_1| \leq \frac{1}{2} \times 10^{-3}$.
因此 $m - n + 1 = 1 - n = -3 \Rightarrow n = 4$, 即 x_1 具有 4 位有效数字;

举例

例1. 3.142, 3.141, $\frac{22}{7}$ 分别作为 π 的近似值, 各有几位有效数字?

【解】 $\pi = 3.14159265 \cdots$. 记 $x_1 = 3.142, x_2 = 3.141, x_3 = \frac{22}{7}$. 本题 $m = 0$

- $\pi - x_1 = 3.14159265 \cdots - 3.142 = -0.00040 \cdots \Rightarrow |\pi - x_1| \leq \frac{1}{2} \times 10^{-3}$.
因此 $m - n + 1 = 1 - n = -3 \Rightarrow n = 4$, 即 x_1 具有 4 位有效数字;
- $\pi - x_2 = 3.14159265 \cdots - 3.141 = 0.00059 \cdots \Rightarrow |\pi - x_2| \leq \frac{1}{2} \times 10^{-2}$.
因此 $m - n + 1 = 1 - n = -2 \Rightarrow n = 3$, 即 x_2 具有 3 位有效数字;

举例

例1. 3.142, 3.141, $\frac{22}{7}$ 分别作为 π 的近似值, 各有几位有效数字?

【解】 $\pi = 3.14159265 \dots$. 记 $x_1 = 3.142, x_2 = 3.141, x_3 = \frac{22}{7}$. 本题 $m = 0$

- $\pi - x_1 = 3.14159265 \dots - 3.142 = -0.00040 \dots \Rightarrow |\pi - x_1| \leq \frac{1}{2} \times 10^{-3}$.
因此 $m - n + 1 = 1 - n = -3 \Rightarrow n = 4$, 即 x_1 具有4位有效数字;
- $\pi - x_2 = 3.14159265 \dots - 3.141 = 0.00059 \dots \Rightarrow |\pi - x_2| \leq \frac{1}{2} \times 10^{-2}$.
因此 $m - n + 1 = 1 - n = -2 \Rightarrow n = 3$, 即 x_2 具有3位有效数字;
- $\pi - x_3 = 3.14159 \dots - 3.14285 \dots = 0.00126 \dots \Rightarrow |\pi - \frac{22}{7}| \leq \frac{1}{2} \times 10^{-2}$.
因此 x_3 也具有3位有效数字。

举例...

例2. 说明如果以 m/s^2 为单位, 重力常数 $g \approx 9.80m/s^2$; 若以 km/s^2 为单位, $g \approx 0.00980km/s^2$, 它们都具有3位有效数字。

举例...

例2. 说明如果以 m/s^2 为单位, 重力常数 $g \approx 9.80m/s^2$; 若以 km/s^2 为单位, $g \approx 0.00980km/s^2$, 它们都具有3位有效数字。

【解】

- 按第一种写法, $m = 0, n = 3$, 此时

$$|g - 9.80| \leq \frac{1}{2} \times 10^{-2}.$$

举例...

例2. 说明如果以 m/s^2 为单位, 重力常数 $g \approx 9.80m/s^2$; 若以 km/s^2 为单位, $g \approx 0.00980km/s^2$, 它们都具有3位有效数字。

【解】

- 按第一种写法, $m = 0, n = 3$, 此时

$$|g - 9.80| \leq \frac{1}{2} \times 10^{-2}.$$

- 按第二种写法, $m = -3, n = 3$, 此时

$$|g - 0.00980| \leq \frac{1}{2} \times 10^{-5}.$$

举例...

例2. 说明如果以 m/s^2 为单位, 重力常数 $g \approx 9.80m/s^2$; 若以 km/s^2 为单位, $g \approx 0.00980km/s^2$, 它们都具有3位有效数字。

【解】

- 按第一种写法, $m = 0, n = 3$, 此时

$$|g - 9.80| \leq \frac{1}{2} \times 10^{-2}.$$

- 按第二种写法, $m = -3, n = 3$, 此时

$$|g - 0.00980| \leq \frac{1}{2} \times 10^{-5}.$$

- 它们虽然写法不同, 但是都具有3位有效数字。

举例...

例2. 说明如果以 m/s^2 为单位, 重力常数 $g \approx 9.80m/s^2$; 若以 km/s^2 为单位, $g \approx 0.00980km/s^2$, 它们都具有3位有效数字。

【解】

- 按第一种写法, $m = 0, n = 3$, 此时

$$|g - 9.80| \leq \frac{1}{2} \times 10^{-2}.$$

- 按第二种写法, $m = -3, n = 3$, 此时

$$|g - 0.00980| \leq \frac{1}{2} \times 10^{-5}.$$

- 它们虽然写法不同, 但是都具有3位有效数字。
- 它们的绝对误差限因单位不同而不同: $\varepsilon_1 = \frac{1}{2} \times 10^{-2}m/s^2, \varepsilon_2 = \frac{1}{2} \times 10^{-5}km/s^2$.

举例...

例2. 说明如果以 m/s^2 为单位, 重力常数 $g \approx 9.80m/s^2$; 若以 km/s^2 为单位, $g \approx 0.00980km/s^2$, 它们都具有3位有效数字。

【解】

- 按第一种写法, $m = 0, n = 3$, 此时

$$|g - 9.80| \leq \frac{1}{2} \times 10^{-2}.$$

- 按第二种写法, $m = -3, n = 3$, 此时

$$|g - 0.00980| \leq \frac{1}{2} \times 10^{-5}.$$

- 它们虽然写法不同, 但是都具有3位有效数字。
- 它们的绝对误差限因单位不同而不同: $\varepsilon_1 = \frac{1}{2} \times 10^{-2}m/s^2, \varepsilon_2 = \frac{1}{2} \times 10^{-5}km/s^2$.
- 但相对误差相同: $\varepsilon_r = 0.005/9.80 = 0.000005/0.00980$. 即绝对误差限有量纲, 相对误差限无量纲。

有效数字与相对误差限的关系

定理1 有效数字与相对误差限的关系定理

有效数字与相对误差限的关系

定理1 有效数字与相对误差限的关系定理

设近似数 $\tilde{x}$ 可表示为

$$\tilde{x} = \pm 10^m \times (a_1 + a_2 \times 10^{-1} + \cdots + a_l \times 10^{-(l-1)}),$$

有效数字与相对误差限的关系

定理1 有效数字与相对误差限的关系定理

设近似数 $\tilde{x}$ 可表示为

$$\tilde{x} = \pm 10^m \times (a_1 + a_2 \times 10^{-1} + \cdots + a_l \times 10^{-(l-1)}),$$

其中 $a_i (i = 1, 2, \cdots, l)$ 是0到9中的一个数字, $a_1 \neq 0$, m 为整数。

有效数字与相对误差限的关系

定理1 有效数字与相对误差限的关系定理

设近似数 $\tilde{x}$ 可表示为

$$\tilde{x} = \pm 10^m \times (a_1 + a_2 \times 10^{-1} + \cdots + a_l \times 10^{-(l-1)}),$$

其中 $a_i (i = 1, 2, \cdots, l)$ 是0到9中的一个数字, $a_1 \neq 0$, m 为整数。若 $\tilde{x}$ 具有 n 位有效数字, 则其相对误差限

$$\varepsilon_r \leq \frac{1}{2a_1} \times 10^{-(n-1)};$$

有效数字与相对误差限的关系

定理1 有效数字与相对误差限的关系定理

设近似数 $\tilde{x}$ 可表示为

$$\tilde{x} = \pm 10^m \times (a_1 + a_2 \times 10^{-1} + \cdots + a_l \times 10^{-(l-1)}),$$

其中 $a_i (i = 1, 2, \cdots, l)$ 是0到9中的一个数字, $a_1 \neq 0$, m 为整数。若 $\tilde{x}$ 具有 n 位有效数字, 则其相对误差限

$$\varepsilon_r \leq \frac{1}{2a_1} \times 10^{-(n-1)};$$

反之, 若 $\tilde{x}$ 的相对误差限 $\varepsilon_r \leq \frac{1}{2(a_1+1)} \times 10^{-(n-1)}$,

有效数字与相对误差限的关系

定理1 有效数字与相对误差限的关系定理

设近似数 $\tilde{x}$ 可表示为

$$\tilde{x} = \pm 10^m \times (a_1 + a_2 \times 10^{-1} + \cdots + a_l \times 10^{-(l-1)}),$$

其中 $a_i (i = 1, 2, \cdots, l)$ 是0到9中的一个数字, $a_1 \neq 0$, m 为整数。若 $\tilde{x}$ 具有 n 位有效数字, 则其相对误差限

$$\varepsilon_r \leq \frac{1}{2a_1} \times 10^{-(n-1)};$$

反之, 若 $\tilde{x}$ 的相对误差限 $\varepsilon_r \leq \frac{1}{2(a_1+1)} \times 10^{-(n-1)}$, 则 $\tilde{x}$ 至少具有 n 位有效数字。

定理1的证明

由条件

$$\tilde{x} = \pm 10^m \times (a_1 + a_2 \times 10^{-1} + \cdots + a_l \times 10^{-(l-1)}),$$

可知,

定理1的证明

由条件

$$\tilde{x} = \pm 10^m \times (a_1 + a_2 \times 10^{-1} + \cdots + a_l \times 10^{-(l-1)}),$$

可知, $a_1 \times 10^m \leq |\tilde{x}| < (a_1 + 1) \times 10^m$.

定理1的证明

由条件

$$\tilde{x} = \pm 10^m \times (a_1 + a_2 \times 10^{-1} + \cdots + a_l \times 10^{-(l-1)}),$$

可知, $a_1 \times 10^m \leq |\tilde{x}| < (a_1 + 1) \times 10^m$. 当 $\tilde{x}$ 具有 n 位有效数字时,

定理1的证明

由条件

$$\tilde{x} = \pm 10^m \times (a_1 + a_2 \times 10^{-1} + \cdots + a_l \times 10^{-(l-1)}),$$

可知, $a_1 \times 10^m \leq |\tilde{x}| < (a_1 + 1) \times 10^m$. 当 $\tilde{x}$ 具有 n 位有效数字时,

$$\varepsilon_r = \frac{|x - \tilde{x}|}{|\tilde{x}|} \leq \frac{0.5 \times 10^{m-n+1}}{a_1 \times 10^m} = \frac{1}{2a_1} \times 10^{-n+1};$$

定理1的证明

由条件

$$\tilde{x} = \pm 10^m \times (a_1 + a_2 \times 10^{-1} + \cdots + a_l \times 10^{-(l-1)}),$$

可知, $a_1 \times 10^m \leq |\tilde{x}| < (a_1 + 1) \times 10^m$. 当 $\tilde{x}$ 具有 n 位有效数字时,

$$\varepsilon_r = \frac{|x - \tilde{x}|}{|\tilde{x}|} \leq \frac{0.5 \times 10^{m-n+1}}{a_1 \times 10^m} = \frac{1}{2a_1} \times 10^{-n+1};$$

反之, 由

$$|x - \tilde{x}| = |\tilde{x}| \varepsilon_r < (a_1 + 1) \times 10^m \times \frac{1}{2(a_1 + 1)} \times 10^{-n+1} = \frac{1}{2} \times 10^{m-n+1},$$

定理1的证明

由条件

$$\tilde{x} = \pm 10^m \times (a_1 + a_2 \times 10^{-1} + \cdots + a_l \times 10^{-(l-1)}),$$

可知, $a_1 \times 10^m \leq |\tilde{x}| < (a_1 + 1) \times 10^m$. 当 $\tilde{x}$ 具有 n 位有效数字时,

$$\varepsilon_r = \frac{|x - \tilde{x}|}{|\tilde{x}|} \leq \frac{0.5 \times 10^{m-n+1}}{a_1 \times 10^m} = \frac{1}{2a_1} \times 10^{-n+1};$$

反之, 由

$$|x - \tilde{x}| = |\tilde{x}| \varepsilon_r < (a_1 + 1) \times 10^m \times \frac{1}{2(a_1 + 1)} \times 10^{-n+1} = \frac{1}{2} \times 10^{m-n+1},$$

可知 $\tilde{x}$ 至少具有 n 位有效数字。

定理1的证明

由条件

$$\tilde{x} = \pm 10^m \times (a_1 + a_2 \times 10^{-1} + \cdots + a_l \times 10^{-(l-1)}),$$

可知, $a_1 \times 10^m \leq |\tilde{x}| < (a_1 + 1) \times 10^m$. 当 $\tilde{x}$ 具有 n 位有效数字时,

$$\varepsilon_r = \frac{|x - \tilde{x}|}{|\tilde{x}|} \leq \frac{0.5 \times 10^{m-n+1}}{a_1 \times 10^m} = \frac{1}{2a_1} \times 10^{-n+1};$$

反之, 由

$$|x - \tilde{x}| = |\tilde{x}| \varepsilon_r < (a_1 + 1) \times 10^m \times \frac{1}{2(a_1 + 1)} \times 10^{-n+1} = \frac{1}{2} \times 10^{m-n+1},$$

可知 $\tilde{x}$ 至少具有 n 位有效数字。

定理1说明, 有效数字越多, 相对误差限越小!

举例

例3. 要使 $\sqrt{20}$ 近似值的相对误差限小于0.1%, 要取几位有效数字?

举例

例3. 要使 $\sqrt{20}$ 近似值的相对误差限小于0.1%, 要取几位有效数字?

解: 假设要取 n 位有效数字。

举例

例3. 要使 $\sqrt{20}$ 近似值的相对误差限小于0.1%, 要取几位有效数字?

解: 假设要取 n 位有效数字。因 $\sqrt{20} = 4. \cdots$, 故 $a_1 = 4$.

举例

例3. 要使 $\sqrt{20}$ 近似值的相对误差限小于0.1%, 要取几位有效数字?

解: 假设要取 n 位有效数字。因 $\sqrt{20} = 4. \dots$, 故 $a_1 = 4$. 由定理1有

$$\varepsilon_r \leq \frac{1}{2a_1} \times 10^{-n+1} = \frac{1}{8} \times 10^{-n+1} < 0.1\% = 10^{-3}.$$

举例

例3. 要使 $\sqrt{20}$ 近似值的相对误差限小于0.1%, 要取几位有效数字?

解: 假设要取 n 位有效数字。因 $\sqrt{20} = 4. \dots$, 故 $a_1 = 4$. 由定理1有

$$\varepsilon_r \leq \frac{1}{2a_1} \times 10^{-n+1} = \frac{1}{8} \times 10^{-n+1} < 0.1\% = 10^{-3}.$$

即, 要成立 $\frac{1}{8} \times 10^{-n+1} < 10^{-3}$, n 至少等于4。

举例

例3. 要使 $\sqrt{20}$ 近似值的相对误差限小于0.1%, 要取几位有效数字?

解: 假设要取 n 位有效数字。因 $\sqrt{20} = 4. \dots$, 故 $a_1 = 4$. 由定理1有

$$\varepsilon_r \leq \frac{1}{2a_1} \times 10^{-n+1} = \frac{1}{8} \times 10^{-n+1} < 0.1\% = 10^{-3}.$$

即, 要成立 $\frac{1}{8} \times 10^{-n+1} < 10^{-3}$, n 至少等于4。

因此, 只需对 $\sqrt{20}$ 的近似值取4位有效数字, 就可以保证其相对误差限小于0.1%。

举例

例3. 要使 $\sqrt{20}$ 近似值的相对误差限小于0.1%, 要取几位有效数字?

解: 假设要取 n 位有效数字。因 $\sqrt{20} = 4. \dots$, 故 $a_1 = 4$. 由定理1有

$$\varepsilon_r \leq \frac{1}{2a_1} \times 10^{-n+1} = \frac{1}{8} \times 10^{-n+1} < 0.1\% = 10^{-3}.$$

即, 要成立 $\frac{1}{8} \times 10^{-n+1} < 10^{-3}$, n 至少等于4。

因此, 只需对 $\sqrt{20}$ 的近似值取4位有效数字, 就可以保证其相对误差限小于0.1%。

查开方表可得 $\sqrt{20} \approx 4.472$ 。

第一章 误差与误差分析

第二节 数值运算的误差估计

1.2.1 浮点数在计算机中的表示和处理

上海财经大学 数学学院

十进制和 β 进制数

在计算机，任一实数可以表示为：

$$x = \pm 10^c \times 0.a_1a_2a_3\cdots,$$

其中, $a_i \in \{0, 1, 2, \cdots, 9\}$ ($i = 1, 2, \cdots$) , c 为整数。

十进制和 β 进制数

在计算机，任一实数可以表示为：

$$x = \pm 10^c \times 0.a_1a_2a_3\cdots,$$

其中, $a_i \in \{0, 1, 2, \cdots, 9\}$ ($i = 1, 2, \cdots$) , c 为整数。上式表示的 x 称为十进制浮点数。

十进制和 β 进制数

在计算机，任一实数可以表示为：

$$x = \pm 10^c \times 0.a_1a_2a_3\cdots,$$

其中, $a_i \in \{0, 1, 2, \cdots, 9\}$ ($i = 1, 2, \cdots$) , c 为整数。上式表示的 x 称为十进制浮点数。

也可以定义更为一般的 β 进制浮点数：

$$x = \pm \beta^c \times 0.a_1a_2a_3\cdots,$$

其中, $a_i \in \{0, 1, 2, \cdots, \beta - 1\}$ ($i = 1, 2, \cdots$) .

计算机能精确表示的数

由于计算机本身的限制，不可能用无限多个 a_i 来表示 x ，因此一般一个实数在计算机里可以被精确地表示为：

$$\tilde{x} = \pm \beta^c \times 0.a_1a_2a_3 \cdots a_t,$$

其中, $a_i \in \{0, 1, \cdots, \beta - 1\}$ ($i = 1, \cdots, t$) , 这里 t 是正整数。

计算机能精确表示的数

由于计算机本身的限制，不可能用无限多个 a_i 来表示 x ，因此一般一个实数在计算机里可以被精确地表示为：

$$\tilde{x} = \pm \beta^c \times 0.a_1a_2a_3 \cdots a_t,$$

其中, $a_i \in \{0, 1, \cdots, \beta - 1\}$ ($i = 1, \cdots, t$) , 这里 t 是正整数。
可以看出,计算机能精确表示的数只有有限个。

计算机中的机器数系

把计算机能精确表示的有限个数所形成的集合称为计算机的机器数系。用以下记号表示：

$$F(\beta, t, L, U) = \left\{ \pm \beta \times 0.a_1 \cdots a_t, a_i \in \{0, \cdots, \beta - 1\}; i = 1, \cdots, t; L \leq c \leq U \right\}.$$

其中,

- t : 正整数, 称为计算机的字长;
- c : 整数, 称为计算机的阶码;
- 阶码的取值范围: $L \leq c \leq U$ 。其中, L, U 为固定整数;
- $0.a_1 a_2 \cdots a_t$: 称为计算机中浮点数的尾数。

由于对不同的计算机, t, L, U 可能取不同的值, 因此不同的计算机系统可能对应不同的机器数系。

而数 $\tilde{x} = \pm \beta^c \times 0.a_1 a_2 a_3 \cdots a_t \in F(\beta, t, L, U)$ 则被称为 t 位 β 进制浮点数。

机器数系的特点和溢出错误

根据以上机器数系的定义，我们总结机器数系具有以下特点：

- ① F 是一个离散的有限数集；
- ② F 中有一个最大的正数 M 和最小的正数 m . 比如：在 $F(10, 4, -99, 99)$ 中，

$$M = 10^{99} \times 0.9999, \quad m = 10^{-99} \times 0.0001;$$

- ③ 若需要计算机表示的实数 $|x| > M$ ，则计算机产生上溢错误；
若需要计算机表示的实数 $|x| < m$ ，则计算机产生下溢错误；
- ④ 如果产生上溢错误，计算机会中断程序，等待处理；
如果产生下溢错误，计算机会直接把该数用零表示，即机器零。
- ⑤ 在目前最新的IEEE754浮点运算规则中，对于上、下溢出已有对应措施，如使用 subnormal 数表示上、下溢出浮点数，并可以正常运算。用特殊数值表示 NaN(非数) 等。

计算机对数的接收

给定实数 x , 计算机的接收方式是:

- ① 若 $x \in F(\beta, t, L, U)$, 则原样接收 x ;
- ② 若 $x \notin F(\beta, t, L, U)$, 但是 $m \leq x \leq M$,
则用 $F(\beta, t, L, U)$ 中最接近 x 的数 $fl(x)$ 表示 x , 并记录。

计算机对数的处理

计算机对接收到的数只能做加减乘除四则运算(现代计算机还能做开方等基本运算)，其运算方式为：

- ① 加减法：先向上对阶，后运算，再舍入；
- ② 乘除法：先运算，再舍入。

举例

例：假设某一计算机使用的数系为 $F(10, 4, -90, 90)$,

$$fl(x_1) = 0.2337 \times 10^{-1}, \quad fl(x_2) = 0.3364 \times 10^2$$

是计算机接收到的两个实数，则

$$\begin{aligned} fl(x_1 + x_2) &= fl(0.2337 \times 10^{-1} + 0.3364 \times 10^2) \\ &\stackrel{\text{对阶}}{=} fl(0.0002337 \times 10^2 + 0.3364 \times 10^2) \\ &\stackrel{\text{运算}}{=} fl(0.3366337 \times 10^2) \\ &\stackrel{\text{舍入}}{=} 0.3366 \times 10^2, \\ fl(x_1 x_2) &= fl(0.2337 \times 10^{-1} \times 0.3364 \times 10^2) \\ &\stackrel{\text{运算}}{=} fl(0.7861668 \times 10^0) \\ &\stackrel{\text{舍入}}{=} 0.7862 \times 10^0 = 0.7862. \end{aligned}$$

第一章 误差与误差分析

第二节 数值运算的误差估计

1.2.2 舍入误差和精度

上海财经大学 数学学院

舍入误差产生的原因

若计算机的数系为 $F(\beta, t, L, U)$. 给定某个实数

$$x = \pm 0.a_1 a_2 \cdots a_t \cdots \times \beta^c$$

其中 $a_i \in \{0, 1, \cdots, \beta - 1\} (i = 1, 2, \cdots)$, $a_1 \neq 0$, $x \notin F(\beta, t, L, U)$, 而且满足 $m < |x| < M$, 这里 m 和 M 分别是 F 中的最小和最大的正数. 计算机经舍入以后, 以 $fl(x)$ 接收 x , 即 $fl(x) = \pm \tilde{a} \times \beta^c$, 其中

$$\tilde{a} = \begin{cases} 0.a_1 \cdots a_t, & 0 \leq a_{t+1} < \frac{\beta}{2}, \\ 0.a_1 \cdots a_t + \beta^{-t}, & a_{t+1} \geq \frac{\beta}{2}. \end{cases}$$

这样, 计算机对 x 的舍入就产生了误差, 称为舍入误差。

从舍入的方式来看, 舍入后的结果与源数之间的绝对误差绝对值不会超过 $fl(x)$ 末位的半个单位。

舍入误差的误差限

根据以上舍入方式，因舍入产生的绝对误差满足：

$$|e| = |x - fl(x)| \leq 0.5 \times \beta^{c-t},$$

相对误差满足：

$$|e_r| = \frac{|x - fl(x)|}{|x|} \leq \frac{0.5 \times \beta^{c-t}}{0.1 \times \beta^c} = 0.5 \times \beta^{1-t}.$$

计算机的精度

前式表明: 计算机的舍入相对误差限与源数 x 本身并无关系, 只与计算机的字长 t 有关. 因此我们可定义 $\text{eps} = 0.5 \times \beta^{1-t}$ 为计算机的精度.

显然字长 t 越大, 精度越高. 在数值计算中, 为了提高计算精度, 有时要用双字长来处理数据, 双字长数据也称为双精度数.

第一章 误差与误差分析

第二节 数值运算的误差估计

1.2.3 四则运算与函数值计算的误差估计

上海财经大学 数学学院

四则运算误差的传播与估计

为了了解经四则运算以后, 误差的变化情况, 我们采用微分作简单描述.

- 把绝对误差看作差分: $e = x^* - x = dx$;
- 则相对误差 $e_r = \frac{e}{x^*} \approx \frac{dx}{x} = d \ln x$.

利用以上关系式可得:

- $d(x \pm y) = dx \pm dy$. 即两数和(差)的误差等于两数误差之和(差);
- $d(xy) = ydx + xdy$;
- $d(x/y) = \frac{ydx - xdy}{y^2}$, $y \neq 0$;
- $d \ln(xy) = d \ln x + d \ln y$. 即两数积的相对误差等于两数相对误差之积;
- $d \ln \left(\frac{x}{y} \right) = d \ln x - d \ln y$. 两数商的相对误差等于两数相对误差之差.

使用泰勒展开进行函数值计算的误差估计

设 $f(x) \in C(a, b)$, $x, \tilde{x} \in (a, b)$. 以近似值 $\tilde{x}$ 的函数值 $f(\tilde{x})$ 来近似 $f(x)$, 其误差界记为 $\varepsilon(f(\tilde{x}))$, 则由函数 $f(x)$ 在 $\tilde{x}$ 处的Taylor展开

$$f(x) - f(\tilde{x}) = f'(\tilde{x})(x - \tilde{x}) + \frac{f''(\xi)}{2}(x - \tilde{x})^2, \quad \xi \text{ 介于 } x, \tilde{x} \text{ 之间.}$$

取绝对值

$$\varepsilon(f(\tilde{x})) = |f(x) - f(\tilde{x})| \leq |f'(\tilde{x})|\varepsilon(\tilde{x}) + \frac{|f''(\xi)|}{2}\varepsilon^2(\tilde{x}).$$

若可以假定 $f''(\tilde{x})$ 与 $f'(\tilde{x})$ 的比值不大, 那么忽略含有 $\varepsilon^2(\tilde{x})$ 的高阶项, 便可以得到计算函数的误差限:

$$\varepsilon(f(\tilde{x})) \approx |f'(\tilde{x})|\varepsilon(\tilde{x}).$$

使用泰勒展开进行函数值计算的误差估计

如果 f 是多元函数, 例如计算 $A = f(x_1, x_2, \dots, x_n)$. 若 $x_1, \dots, x_n$ 的近似值为 $\tilde{x}_1, \dots, \tilde{x}_n$, 则 A 的近似值 $\tilde{A} = f(\tilde{x}_1, \dots, \tilde{x}_n)$. 于是利用多元函数的Taylor展开, 同样省略高阶项可得

$$\begin{aligned} e(\tilde{A}) &= \tilde{A} - A = f(\tilde{x}_1, \dots, \tilde{x}_n) - f(x_1, \dots, x_n) \\ &\approx \sum_{k=1}^n \left[\frac{\partial f(\tilde{x}_1, \dots, \tilde{x}_n)}{\partial x_k} \right] (\tilde{x}_k - x_k) \stackrel{\text{def}}{=} \sum_{k=1}^n \left(\frac{\partial \tilde{f}}{\partial x_k} \right) e_k \end{aligned}$$

于是误差限

$$\varepsilon(\tilde{A}) \approx \sum_{k=1}^n \left| \left(\frac{\partial \tilde{f}}{\partial x_k} \right) \right| e_k.$$

相对误差限为

$$\varepsilon_r = \varepsilon_r(\tilde{A}) = \frac{\varepsilon(\tilde{A})}{|\tilde{A}|} \approx \sum_{k=1}^n \left| \left(\frac{\partial \tilde{f}}{\partial x_k} \right) \right| \frac{e_k}{|\tilde{A}|}.$$

例题

已测得某场地长 l 的值为 $\tilde{l} = 110\text{m}$ ，宽 d 的值为 $\tilde{d} = 80\text{m}$ ，已知 $|l - \tilde{l}| \leq 0.2\text{m}$ ， $|d - \tilde{d}| \leq 0.1\text{m}$ 。试求面积 $s = ld$ 的绝对误差限与相对误差限。

解： $\because s = ld, \frac{\partial s}{\partial l} = d, \frac{\partial s}{\partial d} = l. \therefore$ 由前面推导的结果可知

$$\varepsilon(\tilde{s}) \approx \left| \left(\frac{\partial \tilde{s}}{\partial l} \right) \right| \varepsilon(\tilde{l}) + \left| \left(\frac{\partial \tilde{s}}{\partial d} \right) \right| \varepsilon(\tilde{d}),$$

其中

$$\left(\frac{\partial \tilde{s}}{\partial l} \right) = \tilde{d} = 80\text{m}, \quad \left(\frac{\partial \tilde{s}}{\partial d} \right) = \tilde{l} = 110\text{m},$$

而题目的条件告诉我们： $\varepsilon(\tilde{l}) = 0.2\text{m}$ ， $\varepsilon(\tilde{d}) = 0.1\text{m}$ ，于是绝对误差限

$$\varepsilon(\tilde{s}) \approx 80 \times 0.2 + 110 \times 0.1 = 27(\text{m}^2);$$

相对误差限

$$\varepsilon_r(\tilde{s}) = \frac{\varepsilon(\tilde{s})}{|\tilde{s}|} = \frac{\varepsilon(\tilde{s})}{\tilde{l}\tilde{d}} \approx \frac{27}{8800} = 0.31\%.$$

第一章 误差与误差分析

第三节 算法的稳定性与避免误差危害

上海财经大学 数学学院

算法与数值稳定

算法的定义

对一些已知数据, 按某种规定的顺序, 进行有限次四则运算, 求出所关心的未知量的整个计算步骤称为算法.

算法数值稳定的定义

一个算法, 如果输入数据有误差, 但在计算过程中, 舍入误差不增长, 则称此算法是数值稳定的; 否则称此算法为不稳定的.

如何构造数值稳定的算法?

构造数值稳定算法的几个原则:

1. 防止大数"吃掉"小数.

例如, 在某台数系为 $F(10, 4, -10, 10)$ 的计算机上, 若计算 $x_1 + x_2 = 10^4 + 4$, 需要向上对阶.

$$fl(x_1) = 0.1000 \times 10^5, \quad fl(x_2) = 0.4000 \times 10^1$$

$$f(x_1 + x_2) = 0.1000 \times 10^5 + 0.00004 \times 10^5$$

$$= 0.10004 \times 10^5 \stackrel{\text{舍入}}{=} 0.1000 \times 10^5.$$

小数4被大数 10^4 "吃掉了". 因此我们需要避免大数和小数相加.

如何构造数值稳定的算法?

2. 要控制舍入误差的积累和传播.

例如: 要计算数列

$$I_n = \int_0^1 \frac{x^n}{x+5} dx$$

可在计算出定积分以后, 利用递推公式

$$I_n = -5I_{n-1} + \frac{1}{n}$$

来求解. 其中, 初值

$$I_0 = \int_0^1 \frac{1}{x+5} dx = \ln 6 - \ln 5.$$

根据 I_n 的表达式可知 $I_n > 0$. 但是, 如果我们以单精度运算, 即

$$I_0 = \ln 6 - \ln 5 \approx 0.1823216$$

那么, 计算 I_0 所产生的舍入误差会很快积累, 并最终导致计算出错.

如何构造数值稳定的算法？

表 1: 舍入误差的传播和积累

n	I_n 的计算值	I_n 的精确值	相对误差
0	0.1823216	0.182321557	2.37E-07
1	0.088392	0.088392216	2.44E-06
2	0.05804	0.05803892	1.86E-05
3	0.043133333	0.043138734	0.000125195
4	0.034333333	0.03430633	0.000787137
5	0.028333333	0.028468352	0.004742772
6	0.025	0.024324906	0.02775322
7	0.017857143	0.021232615	0.158975815
8	0.035714286	0.018836924	0.895972252
9	-0.067460317	0.01692649	4.985487729

如何构造数值稳定的算法?

产生这一计算失真的主要原因是: 使用递推公式

$$I_n = -5I_{n-1} + \frac{1}{n}$$

会使由 I_0 带来的舍入误差在每次迭代中扩大5倍. 因此这一算法在数值上是不稳定的.
我们可以采用另一种数学上等价的算法:

$$I_{n-1} = -\frac{1}{5}I_n + \frac{1}{5n}$$

来改进这一问题. 具体做法是: 先根据 I_m 的积分计算公式, 估计出 m 充分大时的值, 再利用上式依次计算出 $I_{m-1}, \dots, I_n, I_{n-1}, \dots, I_1, I_0$.

如何构造数值稳定的算法?

3. 要避免两个相近的数相减.

两个相近的数相减会引起有效数字的严重损失, 从而导致相对误差增大.

例如: 计算 $\sqrt{x+1} - \sqrt{x}$ 时, 用等价的公式 $1/(\sqrt{x+1} + \sqrt{x})$ 来计算, 将得到更好的计算效果.

4. 要避免绝对值很小的数作除数.

由于

$$e\left(\frac{x}{y}\right) \approx d\left(\frac{x}{y}\right) = \frac{ydx - xdy}{y} \approx \frac{ye(x) - xe(y)}{y^2}$$

因此, 当 $|y|$ 很小时, $\left|e\left(\frac{x}{y}\right)\right|$ 可能会变得很大.

要避免这种情况出现, 也可以采用等价公式来计算. 比如, 在计算 $\frac{1-\cos x}{\sin x}$ 时, 若 $\sin x$ 绝对值很小, 则可以采用如下等价公式来计算:

$$\frac{1-\cos x}{\sin x} = \frac{(1-\cos x)(1+\cos x)}{\sin x(1+\cos x)} = \frac{\sin x}{1+\cos x}.$$

如何构造数值稳定的算法?

5. 减少运算次数,避免误差积累.

减少算法的计算量, 不仅可以节省资源 (CPU 时间是一种宝贵的资源), 还能减少舍入误差的传播环节.

例如: 计算多项式函数的值

$$P_n(x) = a_0 + a_1x + a_2x^2 + \cdots + a_nx^n.$$

如果直接计算, 需要约 $2n$ 次乘法 (计算 $x^2, \cdots, x^n$ 需要 $n - 1$ 次乘法, 计算 $a_ix^i, i = 1, \cdots, n$ 需要 n 次乘法). 但如果用秦九韶算法:

$$P_n(x) = \left(\cdots \left((a_nx + a_{n-1})x + a_{n-2} \right)x + \cdots + a_1 \right)x + a_0$$

则总共需要 n 次乘法! 秦九韶算法逻辑结构简单, 计算量小, 是数值稳定的算法.

如何构造数值稳定的算法?

6. 在编程时, 也要注意避免浮点数和0比较.

考虑以下两个语句:

(1) `if A=0 then goto B else goto C;`

(2) `if  $A < 10^{-12}$  then goto B else goto C.`

语句(1)应避免使用. 为什么?

其他一些重要的数值稳定的算法

- 采用迭代法开方求值 (Newton's method) .
- 以直代曲化整为零。 (Linearization method) .
- 加权平均法。 (Relaxation method) .
- ...