

第三章 函数逼近与快速Fourier变换

第五节 曲线拟合的最小二乘法

张振宇

上海财经大学 数学学院

何为曲线拟合

给定实验数据 $(x_i, y_i), i = 0, 1, \dots, m$, 其中 $y_i = f(x_i)$, 但 $f(x)$ 未知。所谓曲线拟合是指：寻找函数 $S^*(x)$ 与所给实验数据拟合。记

$$\boldsymbol{\delta} = (\delta_0, \dots, \delta_m)^T, \delta_i = S^*(x_i) - y_i, i = 0, 1, \dots, m.$$

设 $\{\varphi_k(x)\}_{k=0}^n$ 是 $C[a, b]$ 上的线性无关函数族。所谓 $S^*(x)$ 与所给实验数据拟合是指寻找 $S^*(x) \in \Phi = \text{span}\{\varphi_0, \dots, \varphi_n\}$, s.t.

$$\|\boldsymbol{\delta}\|_2^2 = \sum_{i=0}^m \delta_i^2 = \sum_{i=0}^m [S^*(x_i) - y_i]^2 = \min_{S(x) \in \Phi} \sum_{i=0}^m [S(x_i) - y_i]^2.$$

注意： $\|\cdot\|_2$ 是向量的2-范数，即 $\|x\|_2 = \sqrt{x_1^2 + \dots + x_n^2}$.

关于曲线拟合的两点说明

- ① 首先，要确定 S^* 的形式（或称为数学模型），即基函数 $\{\varphi_k(x)\}_{k=0}^n$ 的数量与形式。这与问题本身有关！
- ② $\|\delta\|_2^2$ 通常须考虑加权和，即

$$\|\delta\|_2^2 = \sum_{i=0}^m \omega(x_i) [S^*(x_i) - y_i]^2.$$

其中， $\omega(x)$ 是权函数，表示不同数据点的比重。比如 $\omega(x_i)$ 可以表示观测点 (x_i, y_i) 被观测到的次数等。为了保证带权 $\vec{\omega} = [\omega(x_0), \dots, \omega(x_m)]^T$ 的向量内积满足内积的条件，必须有 $\vec{\omega} > \vec{0}$ ，即 $\omega(x_i) > 0, i = 0, 1, \dots, n$.

在确定了权函数和基函数以后，可以求 $S^*(x)$. 以下给出用最小二乘法求进行曲线拟合的推导。

最小二乘法推导

设 $\forall S(x) \in \Phi, S(x) = a_0\varphi_0(x) + \cdots + a_n\varphi_n(x)$. 我们的目标是确定 $S^*(x) = a_0^*\varphi_0(x) + \cdots + a_n^*\varphi_n(x)$ 的系数 $a_k^*, k = 0, \dots, n$. 其计算过程与最佳平方逼近函数的计算过程类似。若定义向量内积:

$$(\varphi_k, \varphi_l) = \sum_{i=0}^m \omega(x_i) \varphi_k(x_i) \varphi_l(x_i), k, l = 0, \dots, n.$$

其中, $\varphi_k = [\varphi_k(x_0), \dots, \varphi_k(x_m)]^T$. 则可得法方程 $G\mathbf{a} = \mathbf{d}$. 其中

$$G = \begin{pmatrix} (\varphi_0, \varphi_0) & \cdots & (\varphi_0, \varphi_n) \\ \vdots & & \vdots \\ (\varphi_n, \varphi_0) & \cdots & (\varphi_n, \varphi_n) \end{pmatrix}, \mathbf{a} = (a_0, \dots, a_n)^T,$$

$\mathbf{d} = [(\mathbf{f}, \varphi_0), \dots, (\mathbf{f}, \varphi_n)]^T, \mathbf{f} = (y_0, \dots, y_n)^T$. 法方程的解 $\mathbf{a}^* = (a_0^*, \dots, a_n^*)^T$ 就是 $S^*(x)$ 的系数。

解的存在唯一性

由于内积定义的变化, $\{\varphi_k(x)\}_{k=0}^n$ 线性无关并不能保证 $\det(G) \neq 0$.

比如, $n = 1, \varphi_0(x) = \sin x, \varphi_1(x) = \sin 2x$. 由于 $\varphi_1(x)/\varphi_0(x) \neq 0$, 故 φ_0, φ_1 线性无关. 但若取 $m = 2, x_i = i\pi, i = 0, 1, 2$, 则 $\varphi_0(x_i) = \varphi_1(x_i) = 0, i = 0, 1, 2$, 此时, 无论权函数 $\omega(x)$ 怎么取, 都有 $G = 0$. 为了保证法方程的系数矩阵非奇异 (否则解做不到存在唯一), 给出以下的 Haar 条件:

定义 3. 10 (Haar 条件)

设 $\varphi_k(x) \in C[a, b] (k = 0, \dots, n)$ 的任意线性组合在点集 $\{x_i, i = 0, 1, \dots, m\} (m \geq n)$ 至多只有 n 个不同的零点, 则称 $\varphi_k(x) (k = 0, \dots, n)$ 在点集 $\{x_i, i = 0, 1, \dots, m\}$ 上满足 Haar 条件.

Haar 条件的另一种叙述是: 给定点集 $X = \{x_0, \dots, x_m\}, m \geq n, S(x)$ 是 $\varphi(x)$ 的某个给定的任意线性组合, 即 $S(x) = a_0\varphi_0(x) + \dots + a_n\varphi_n(x)$. 如果点集 X 中有超过 n 个点是 $S(x)$ 的零点, 那么 $S(x) \equiv 0$, 或者说 $a_0 = \dots = a_n = 0$. 显然 $\sin x, \sin 2x$ 不满足 Haar 条件。

解的存在唯一性（续）

可以证明：只要基函数 $\varphi_k(x)$ ($k = 0, \dots, n$) 在 $x_i, i = 0, 1, \dots, m$ 上满足Haar条件，则 $\det(G) \neq 0$ 。(思考一下怎么证明?) 例如 $\varphi_k(x)$ 取为多项式基 $1, x, \dots, x^n$. 此时法方程一定有唯一解 $\mathbf{a}^*$. 为什么? .

再使用与推导最佳平方逼近函数平方误差最小的过程类似的方法可以证明：

$$\sum_{i=0}^m \omega(x_i) [S^*(x_i) - f(x_i)]^2 \leq \sum_{i=0}^m \omega(x_i) [S(x_i) - f(x_i)]^2, \forall S(x) \in \Phi.$$

从而得到 $S^*(x) = a_0^* \varphi_0(x) + \dots + a_n^* \varphi_n(x)$ 的确是所求的最小二乘解.

从以上的推导可以看出，应用最小二乘法求解曲线拟合问题主要应考虑以下两点：

- 根据给定的数据 (x_i, y_i) ，确定合适的基函数（即确定数学模型）；
- 尽量避免法方程系数矩阵 G 的病态。

曲线拟合问题举例一

例、已知一组实验数据:

x_i	1	2	3	4	5
f_i	4	4.5	6	8	8.5
ω_i	2	1	3	1	1

图中“+”号标识的就是点 $(x_i, f_i)(i = 0, \dots, 4)$. 可以看出用直线拟合比较合适. 因此设 $\varphi_0(x) = 1, \varphi_1(x) = x, S_1(x) = a_0\varphi_0(x) + a_1\varphi_1(x) = a_0 + a_1x$.


记 $\boldsymbol{\varphi}_0 = (1, 1, 1, 1, 1)^T, \boldsymbol{\varphi}_1 = (1, 2, 3, 4, 5)^T, \boldsymbol{f} = (4, 4.5, 6, 8, 8.5)^T$, 则

$$\begin{aligned}(\boldsymbol{\varphi}_0, \boldsymbol{\varphi}_0) &= \sum_{i=0}^4 \omega_i = 8, (\boldsymbol{\varphi}_0, \boldsymbol{\varphi}_1) = (\boldsymbol{\varphi}_1, \boldsymbol{\varphi}_0) = \sum_{i=0}^4 \omega_i x_i = 22, (\boldsymbol{\varphi}_1, \boldsymbol{\varphi}_1) = \sum_{i=0}^4 \omega_i x_i^2 = 74; \\(\boldsymbol{\varphi}_0, \boldsymbol{f}) &= \sum_{i=0}^4 \omega_i f_i = 47, (\boldsymbol{\varphi}_1, \boldsymbol{f}) = \sum_{i=0}^4 \omega_i x_i f_i = 145.5.\end{aligned}$$

法方程为:

$$\begin{pmatrix} 8 & 22 \\ 22 & 74 \end{pmatrix} \begin{pmatrix} a_0 \\ a_1 \end{pmatrix} = \begin{pmatrix} 47 \\ 145.5 \end{pmatrix} \Rightarrow \begin{cases} a_0^* = 2.5648 \\ a_1^* = 1.2037 \end{cases} \Rightarrow S_1^*(x) = 2.5648 + 1.2037x.$$

曲线拟合问题举例一（续）



曲线拟合问题举例二

再看一个不是直线模型的例子。

例、给定实验数据


x_i	1.00	1.25	1.50	1.75	2.00
y_i	5.10	5.79	6.53	7.45	8.46
$\bar{y}_i$	1.629	1.756	1.876	2.008	2.135

从实验数据来看，用指数模型 $y = ae^{bx}$ (a, b 待定)更合适，但是在具体计算时，必须用基函数线性表示，因此需要转为线性形式。

$$y = ae^{bx} \Rightarrow \ln y = \ln a + bx \Rightarrow \bar{y} = A + bx, \quad \bar{y} \stackrel{\text{def}}{=} \ln y, A \stackrel{\text{def}}{=} \ln a.$$

用直线 $\bar{y} = A + bx$ 拟合完数据 $x, \bar{y}$ 后，还原系数 a ，从而得到指数形式的拟合曲线 $y = ae^{bx}$ 。这就是本题的求解思路。

曲线拟合问题举例二（续）



用正交多项式作最小二乘拟合

即使离散内积意义下的Gram矩阵是非奇异，但还是会有法方程组病态的问题。此时若用正交多项式 $\{p_k(x)\}_{k=0}^n$ 为基进行拟合，则可以完全避免 G 病态的问题。

需要指出的是，实际上这里所说的正交多项式并不是前面的Legendre正交多项式。

设给定实验数据 $(x_i, y_i) (i = 0, \dots, m)$ ，权函数 $\omega(x)$ ， $\omega(x_i) > 0$ 。

记 $\mathbf{p}_k = (p_k(x_0), \dots, p_k(x_m))^T$ ， $\mathbf{y} = (y_0, \dots, y_m)^T$ ， $\mathbf{a}^* = (a_0^*, \dots, a_n^*)^T$ ，其中

$$(\mathbf{p}_k, \mathbf{p}_l) = \sum_{i=0}^m \omega(x_i) p_k(x_i) p_l(x_i) = \begin{cases} 0, & l \neq k; \\ A_k \neq 0, & l = k. \end{cases}$$

也就是说，真正正交的并不是多项式，而是向量 $\mathbf{p}_i$ 。因此我们可以从任何给定的基函数 $\varphi_i(x)$ 出发，若得到线性无关的基向量 $\boldsymbol{\varphi}_i$ ，就可以通过正交化方法，比如Gram Schmidt正交化过程，或者Modified Gram Schmidt正交化过程，将向量组 $\{\boldsymbol{\varphi}_i\}$ 进行标准正交化。

因此由向量的标准正交性可知法方程 $G\mathbf{a} = \mathbf{d}$ 化为

$$\begin{pmatrix} (\mathbf{p}_0, \mathbf{p}_0) & & \\ & \ddots & \\ & & (\mathbf{p}_n, \mathbf{p}_n) \end{pmatrix} \begin{pmatrix} a_0 \\ \vdots \\ a_n \end{pmatrix} = \begin{pmatrix} (\mathbf{y}, \mathbf{p}_0) \\ \vdots \\ (\mathbf{y}, \mathbf{p}_n) \end{pmatrix}$$

事实上，由于正交化过程完成的是带权 ω 的标准正交化，因此 $(\mathbf{p}_i, \mathbf{p}_i) = A_i = 1$ ，从而

$$\begin{pmatrix} a_0 \\ \vdots \\ a_n \end{pmatrix} = \begin{pmatrix} (\mathbf{y}, \mathbf{p}_0) \\ \vdots \\ (\mathbf{y}, \mathbf{p}_n) \end{pmatrix}.$$

即

$$a_k^* = (\mathbf{y}, \mathbf{p}_k), \quad k = 0, \dots, n.$$

进而可得 $S^*(x)$ 的表达式。其平方误差为

$$\|\delta\|_2^2 = \|\mathbf{y}\|_2^2 - \sum_{k=0}^n A_k (a_k^*)^2 = \|\mathbf{y}\|_2^2 - \sum_{k=0}^n (a_k^*)^2.$$

