

# 第三章 函数逼近与快速Fourier变换

第一节 函数逼近问题的提出

第二节 最佳一致逼近多项式

张振宇

上海财经大学 数学学院

## 问题的提出

对函数类 $\mathcal{A}$ 中的给定函数 $f(x)$ , 要求在另一类计算较简单的函数类 $\mathcal{B}$ 中, 求一函数 $P(x) \in \mathcal{B} \subseteq \mathcal{A}$ , 使 $P(x)$ 与 $f(x)$ 之差在某种度量意义下最小。

一般 $\mathcal{A}$ 取为 $C[a, b]$ ,  $\mathcal{B}$ 取为 $\mathcal{P}_n$ 或有理函数或三角多项式。本章寻找逼近多项式 $P_n(x)$ 。

一般度量标准取为

- $\|f(x) - P(x)\|_{\infty} = \max_{a \leq x \leq b} |f(x) - P(x)|$  —— 一致逼近或均匀逼近;
- $\|f(x) - P(x)\|_2 = \sqrt{\int_a^b [f(x) - P(x)]^2 dx}$  —— 平方逼近或均方逼近。

## 逼近多项式的存在性

在给出计算逼近多项式 $P_n(x)$ 的方法之前, 应先解决满足要求的逼近多项式是否存在这一问题。即 $\forall f(x) \in C[a, b]$ 是否存在 $P_n(x) \in \mathcal{P}_n$ 一致收敛到 $f(x)$ ?

### 定理 3.1 (Weierstrass定理)

设 $f(x) \in C[a, b]$ , 则 $\forall \varepsilon > 0, \exists P_n(x) \in \mathcal{P}_n$ , s.t.

$$\|f(x) - P_n(x)\|_{\infty} < \varepsilon$$

在 $[a, b]$ 上一致成立。

1912年Bernstein给出以上定理的一个构造性的证明。

## Bernstein多项式

Bernstein构造出一个多项式 $B_n(x)$ :

$$\begin{cases} B_n(f, x) = \sum_{k=0}^n f\left(\frac{k}{n}\right) p_k(x), \\ p_k(x) = C_n^k x^k (1-x)^{n-k}. \end{cases}$$

并证明了  $\lim_{n \rightarrow \infty} B_n(f, x) = f(x)$  在  $[0, 1]$  上一致成立。且若  $f \in C^m[0, 1]$ , 则

$$\lim_{n \rightarrow \infty} B_n^{(m)}(f, x) = f^{(m)}(x).$$

## Bernstein多项式逼近的稳定性

由于

$$\sum_{k=0}^n p_k(x) = \sum_{k=0}^n C_n^k x^k (1-x)^{n-k} = (x + 1 - x)^n = 1.$$

且当  $x \in [0, 1]$  时,  $p_k(x) \geq 0$ , 故

$$\sum_{k=0}^n |p_k(x)| = \sum_{k=0}^n p_k(x) = 1.$$

因此, 只要  $|f(x)| \leq \delta, x \in [0, 1]$ , 则

$$|B_n(f, x)| \leq \max_{0 \leq x \leq 1} |f(x)| \sum_{k=0}^n |p_k(x)| \leq \delta.$$

这表明  $B_n(x)$  逼近  $f(x)$  是稳定的。 (Lagrange插值不稳定、不收敛是因为  $\sum_{k=0}^n |l_k(x)|$  无界。)

## 最佳一致逼近问题

从前面的定理和证明来看，似乎只要 $n \rightarrow \infty$ ，就可以得到满足要求（精度）的一致逼近多项式。可是，即使 $B_n(f, x)$ 对 $f(x)$ 有良好的逼近效果，但因其收敛速度太慢，我们一般不会使用它来逼近 $f(x)$ 。因为这样不符合 $P_n(x)$ 要计算简单快速的原则。

于是Chebyshev从另一个角度提出求一致逼近多项式的问题。即最佳一致逼近或Chebyshev逼近问题。我们简单说明一下：

- 固定多项式 $P_n(x)$ 的次数 $n$ ，即 $P_n(x) \in \mathcal{P}_n$ 。
- 寻找最佳一致逼近多项式 $P_n^*(x)$ 满足

$$\max_{a \leq x \leq b} |f(x) - P_n^*(x)| = \min_{P_n(x) \in \mathcal{P}_n} \max_{a \leq x \leq b} |f(x) - P_n(x)|.$$

以下给出最佳一致逼近问题的数学定义

## 偏差与最小偏差

先给出偏差的定义:

### 定义 3.1 (偏差的定义)

$P_n(x) \in \mathcal{P}_n, f(x) \in C[a, b]$ , 称

$$\Delta(f, P_n(x)) = \|f - P_n\|_\infty = \max_{a \leq x \leq b} |f(x) - P_n(x)|$$

为  $f(x)$  与  $P_n(x)$  在  $[a, b]$  上的偏差。由于  $\Delta(f, P_n(x)) \geq 0$ , 故记

$$E_n = \inf_{P_n \in \mathcal{P}_n} \{\Delta(f, P_n)\} = \inf_{P_n \in \mathcal{P}_n} \max_{a \leq x \leq b} |f(x) - P_n(x)|$$

称其为  $f(x)$  在  $[a, b]$  上的最小偏差。

## 最佳一致逼近多项式的定义和存在性

### 定义 3.2 (最佳一致逼近多项式的定义)

设  $f(x) \in C[a, b]$ , 若  $\exists P_n^*(x) \in \mathcal{P}_n, \Delta(f, P_n^*) = E_n$ , 则称  $P_n^*(x)$  为  $f(x)$  在  $[a, b]$  上的 最佳一致逼近多项式 或 最小偏差逼近多项式。

### 定理 3.2 (最佳一致逼近多项式的存在性定理)

若  $f(x) \in C[a, b]$ , 则总存在  $P_n^*(x) \in \mathcal{P}_n$ , s.t.

$$\|f(x) - P_n^*(x)\|_{\infty} = E_n.$$

(证明略)

为了证明最佳一致逼近多项式的唯一性, 以下引入偏差点的定义, 并给出Chebyshev定理。

## 偏差点的定义

### 定义 3.3 (偏差点的定义)

设  $f(x) \in C[a, b]$ ,  $P(x) \in \mathcal{P}_n$ , 若  $x = x_0$  时, 有

$$|P(x_0) - f(x_0)| = \max_{a \leq x \leq b} |P(x) - f(x)| \stackrel{\text{def}}{=} \mu$$

则称  $x_0$  是  $P(x)$  的偏差点。若

- $P(x_0) - f(x_0) = \mu$ , 则称  $x_0$  是  $f(x)$  的“正”偏差点;
- $P(x_0) - f(x_0) = -\mu$ , 则称  $x_0$  是  $f(x)$  的“负”偏差点。

由于  $P(x) - f(x) \in C[a, b]$ , 故至少  $\exists$  一点  $x_0 \in [a, b]$ , s.t.  $|P(x_0) - f(x_0)| = \mu$ , 即偏差点总是存在的。

## 最佳一致逼近多项式的“正”、“负”偏差点的存在性

定理 3.3 (最佳一致逼近多项式的“正”、“负”偏差点的存在性定理)

若  $P(x) \in \mathcal{P}_n$  是  $f(x) \in C[a, b]$  的最佳一致逼近多项式, 则  $P(x)$  同时存在“正”“负”偏差点。

## 定理3.3的证明

定理3.3可以使用反证法证明。

- 由于 $P(x)$ 是最佳一致逼近多项式, 故 $\mu = E_n$ . 因偏差点总是存在的, 故假设只有“正”偏差点, 没有“负”偏差点, 即

$$P(x) - f(x) > -E_n, \quad \forall x \in [a, b].$$

- 由于 $P(x) - f(x) \in C[a, b]$ , 故一定有最小值存在。不妨设最小值为 $-E_n + 2h, h > 0$ . 则 $-E_n + 2h \leq P(x) - f(x) \leq E_n$ .
- 两边同减去 $h$ 得:  $-E_n + h \leq [P(x) - h] - f(x) \leq E_n - h$ .
- 上式说明多项式 $P(x) - h \in \mathcal{P}_n$ 与 $f(x)$ 的偏差比 $P(x)$ 更小, 其偏差为 $E_n - h$ . 这与 $E_n$ 是最小偏差矛盾。
- 同理可证: 这有“负”偏差点, 没有“正”偏差点也会产生矛盾。因此假设不真, 从而得证: 最佳一致逼近多项式的“正”“负”偏差点同时存在。

# Chebyshev逼近定理

以下为了叙述方便，把最佳一致逼近多项式简称为“最佳逼近多项式”。

## 定理 3.4 (Chebyshev逼近定理)

$P(x) \in \mathcal{P}_n$  是  $f(x) \in C[a, b]$  的最佳逼近多项式的充要条件是  $P(x)$  在  $[a, b]$  上至少有  $n + 2$  个轮流取“正”“负”的偏差点。即有  $n + 2$  个点  $a \leq x_1 < \cdots < x_{n+2} \leq b$ , 使得

$$P(x_k) - f(x_k) = (-1)^k \sigma \|P(x) - f(x)\|_{\infty}, \sigma = \pm 1, k = 1, 2, \cdots, n + 2.$$

这样的点组称为Chebyshev交错点组。

## Chebyshev定理的充分性的证明

由于定理3.4的必要性的证明比较繁琐，我们只给出定理的充分性的证明。

- 若 $\exists Q(x) \in \mathcal{P}_n, Q(x) \neq P(x)$ 且 $\Delta(f, Q) < \Delta(f, P)$ , 则

$$P(x) - Q(x) = [P(x) - f(x)] - [Q(x) - f(x)].$$

这说明：在 $x = x_k (k = 1, \dots, n+2)$ 处， $P(x_k) - Q(x_k)$ 也轮流取正、负。

- 于是 $P(x) - Q(x)$ 在相邻两个正负点 $x_k, x_{k+1}$ 之间，必有 $P(x) - Q(x)$ 的一个零点。故 $P(x) - Q(x)$ 至少有 $n+1$ 个零点。但是 $P(x) - Q(x) \in \mathcal{P}_n$ , 因此只能有 $P(x) \equiv Q(x)$ .
- 这与假设 $Q(x) \neq P(x)$ 矛盾，从而假设不真。充分性得证。

## 最佳逼近多项式的唯一性

作为定理3.4的推论，以下推论3.1给出最佳逼近多项式的唯一性。

### 推论 3.1 (最佳逼近多项式的唯一性定理)

若  $f \in C[a, b]$ , 则在  $\mathcal{P}_n$  中存在唯一的最佳逼近多项式。

存在性已在定理3.2中给出。以下给出唯一性的证明。

## 最佳逼近多项式的唯一性的证明

- 设 $\exists P(x), Q(x) \in \mathcal{P}_n$ , 都是 $f(x)$ 的最佳逼近多项式,  
即 $-E_n \leq P(x) - f(x) \leq E_n, -E_n \leq Q(x) - f(x) \leq E_n$ . 于是

$$-E_n \leq \frac{P(x) + Q(x)}{2} - f(x) \leq E_n$$

即 $R(x) = \frac{1}{2}[P(x) + Q(x)]$ 也是最佳逼近多项式。

- 由定理3.4可知,  $\exists x_1 < \cdots < x_{n+2}$ , s.t.  $R(x)$ 轮流取正负。即

$$|R(x_k) - f(x_k)| = \left| \frac{P(x_k) - f(x_k)}{2} + \frac{Q(x_k) - f(x_k)}{2} \right| = E_n.$$

## 最佳逼近多项式的唯一性的证明 (续)

- 但是因 $|P(x_k) - f(x_k)| \leq E_n, |Q(x_k) - f(x_k)| \leq E_n$ , 故只能

$$\frac{P(x_k) - f(x_k)}{2} = \frac{Q(x_k) - f(x_k)}{2} = \frac{E_n}{2} \quad \text{or} \quad -\frac{E_n}{2}.$$

从而有 $P(x_k) = Q(x_k)$ , 即 $P(x_k) - Q(x_k) = 0, \quad k = 1, \dots, n+2$ .

- 由于 $P(x) - Q(x) \in \mathcal{P}_n$ , 但它有 $n+2$ 个根 $x_k, k = 1, \dots, n+2$ . 因此只能 $P(x) \equiv Q(x)$ . 唯一性得证。

## 最佳逼近多项式是一个Lagrange插值多项式

### 推论 3.2

设 $f(x) \in C[a, b]$ , 则其最佳逼近多项式 $P^*(x) \in \mathcal{P}_n$ 就是 $f(x)$ 的一个Lagrange插值多项式。

证: 由于 $P^*(x)$ 是 $f(x)$ 在 $[a, b]$ 上的最佳逼近多项式, 故由定理3.4可知,  $\exists n+2$ 个轮流取“正”、“负”的偏差点 $x_k, k=1, \dots, n+2$ .

$\because P_n^*(x) - f(x) \in C[a, b],$

$\therefore$ 由零值定理可知 $P_n^*(x) - f(x)$ 在相邻的两个偏差点之间 $(x_k, x_{k+1})$ 中至少有一个零点 $\tilde{x}_k$ , 即满足 $P_n^*(\tilde{x}_k) - f(\tilde{x}_k) = 0, k=1, \dots, n+1$ .

这样 $P_n^*(x)$ 就是满足插值条件 $P_n^*(\tilde{x}_k) = f(\tilde{x}_k), k=1, \dots, n+1$ 的Lagrange插值多项式。证毕。

## 最佳逼近多项式的计算

尽管Chebyshev定理给出了最佳逼近多项式的性质，但是实际中，求最佳逼近多项式却十分困难。这里我们只给出 $n = 1$ 时，即最佳一次逼近多项式的推导过程。可以发现，即使是最佳一次逼近多项式的计算过程也很复杂。

## 举例：最佳一次逼近多项式的计算

例. 设  $f(x) \in C^2[a, b]$ , 且  $f''(x)$  在  $[a, b]$  上不变号, 求  $f(x)$  在  $[a, b]$  上的最佳一次逼近多项式。

解:  $\because f''(x)$  在  $[a, b]$  上不变号,

$\therefore f(x)$  在  $[a, b]$  的凹凸性不变, 不妨设  $f(x)$  在  $[a, b]$  上凹 ( $f''(x) > 0$ ).

由  $y = f(x)$  的形状 (上凹) 以及定理3.4可知: 最佳一次逼近多项式  $P_1(x)$  有三个偏差点  $x_0, x_1, x_2$ .

设  $P_1(x) = a_0 + a_1x$ ,  $a_0, a_1$  为待定系数。则  $[P_1(x) - f(x)]' = a_1 - f'(x)$ .

因  $f''(x)$  在  $[a, b]$  上不变号, 故  $f'(x)$  单调, 从而  $[P_1(x) - f(x)]' = a_1 - f'(x)$  也单调, 因此它在  $(a, b)$  上最多只有一个零点。以  $x_1$  来记 (驻点只能在三个偏差点处取得), 即

$$a_1 - f'(x_1) = 0 \Rightarrow a_1 = f'(x_1).$$

## 举例：最佳一次逼近多项式的计算（续）

既然  $[P_1(x) - f(x)]'$  在  $(a, b)$  除  $x_1$  以外，没有其他零点了，因此另两个偏差点  $x_0, x_2$  只能取到区间的端点，即  $x_0 = a, x_2 = b$ 。

由定理3.4知，偏差点轮流取“正”、“负”。因此，

$$P_1(a) - f(a) = P_1(b) - f(b) = -[P_1(x_1) - f(x_1)].$$

于是

$$P_1(a) - f(a) = P_1(b) - f(b) \Rightarrow a_0 + a_1a - f(a) = a_0 + a_1b - f(b) \quad \dots(1)$$

$$P_1(b) - f(b) = -[P_1(x_1) - f(x_1)] \Rightarrow a_0 + a_1b - f(b) = f(x_1) - a_0 - a_1f(x_1) \quad \dots(2)$$


$$\text{由(1)} \Rightarrow a_1 = \frac{f(b)-f(a)}{b-a} = f'(x_1).$$

$$\text{由(2)} \Rightarrow a_0 = \frac{f(b)+f(x_1)}{2} - \frac{f(b)-f(a)}{b-a} \cdot \frac{b+x_1}{2}.$$

这样就得到了最佳一次逼近多项式。以下给出其几何意义。

## 举例：最佳一次逼近多项式的几何意义

若记点 $M, N, Q$ 的坐标分别为 $(a, f(a)), (b, f(b))$ 和 $(x_1, f(x_1))$ . 则直线 $y = P_1(x)$ 与弦 $MN$ 平行，且过线段 $NQ$ 的中点 $D$ 其坐标记为 $(x_d, y_d)$ .



## 举例：最佳一次逼近多项式的几何意义的证明

可以证明以上的几何意义成立。即直线 $\ell: y - y_d = \frac{f(b)-f(a)}{b-a}(x - x_d)$ 就是 $y = P_1(x)$ 。

考虑到 $x_d = \frac{x_1+b}{2}$ ,  $y_d = \frac{f(x_1)+f(b)}{2}$ , 因此直线 $\ell$ ：

$$y = \frac{f(b) - f(a)}{b - a}x + \frac{f(x_1) + f(b)}{2} - \frac{f(b) - f(a)}{b - a} \cdot \frac{x_1 + b}{2} = a_1x + a_0 = P_1(x).$$

## 例

例：求  $f(x) = \sqrt{1+x^2}$  在  $[0, 1]$  上的最佳一次逼近多项式。

解：

$$f'(x) = \frac{x}{\sqrt{1+x^2}} \geq 0, x \in [0, 1]; \quad a_1 = \frac{f(1) - f(0)}{1 - 0} = \sqrt{2} - 1 \approx 0.4142.$$

$$f'(x_1) = \frac{x_1}{\sqrt{1+x_1^2}} = a_1 \approx 0.4142 \Rightarrow x_1 = \sqrt{\frac{a_1^2}{1-a_1^2}} = \frac{\sqrt{2}-1}{\sqrt{2\sqrt{2}-2}} \approx 0.4551.$$

$$f(x_1) \approx f(0.4551) = \sqrt{1+0.4551^2} \approx 1.0987.$$

$$a_0 = \frac{f(1) + f(0.4551)}{2} - a_1 \frac{1+x_1}{2} \approx 0.9551.$$

$$P_1(x) = 0.9551 + 0.4142x, x \in [0, 1]; \quad \max_{0 \leq x \leq 1} |P_1(x) - f(x)| = |P_1(x_1) - f(x_1)| \approx 0.045.$$

# 第三章 函数逼近与快速Fourier变换

## 第三节 最佳平方逼近

张振宇

上海财经大学 数学学院

## 预备知识（权函数的定义）

如果用 $\|\cdot\|_2$ 作为度量标准，研究 $f(x) \in C[a, b]$ 的最佳逼近函数，就是最佳平方逼近问题。本节介绍最佳平方逼近多项式的相关性质和计算方法。

### 定义 34 (权函数的定义)

在 $[a, b]$ 内，非负函数 $\rho(x)$ 满足

- ①  $\int_a^b |x|^n \rho(x) dx (n = 0, 1, \dots)$  存在；
- ② 对任意非负连续函数 $g(x)$ 都有：若 $\int_a^b g(x) \rho(x) dx = 0$ ，则在 $[a, b]$ 内， $g(x) \equiv 0$ 。

则称 $\rho(x)$ 为区间 $[a, b]$ 上的权函数。

## 内积和内积空间

### 定义 35 (内积和内积空间的定义)

设  $f(x), g(x) \in C[a, b]$ ,  $\rho(x)$  是  $[a, b]$  上的权函数。称积分

$$(f, g) = \int_a^b \rho(x) f(x) g(x) dx$$

为  $f(x)$  与  $g(x)$  在  $[a, b]$  上的内积。易证，这样定义的内积满足以下四条公理：

- ①  $(f, g) = (g, f)$ ; (交换律)
- ②  $(cf, g) = c(f, g)$ ,  $c$  为任意常数; (齐次性)
- ③  $(f_1 + f_2, g) = (f_1, g) + (f_2, g)$ ; (分配律)
- ④  $(f, f) \geq 0$ , 当且仅当  $f = 0$  时,  $(f, f) = 0$ 。(正定性)

满足内积定义的函数空间称为内积空间。

# Euclid范数

## 定义 36 (Euclid范数)

$f(x) \in C[a, b]$ , 称

$$\|f\|_2 = \sqrt{\int_a^b \rho(x) f^2(x) dx} = \sqrt{(f, f)}$$

为  $f(x)$  的 Euclid 范数。

## 定理 35 (Euclid范数的性质)

$\forall f, g \in C[a, b]$ , 有以下结论:

- ①  $|(f, g)| \leq \|f\|_2 \|g\|_2$ ; (Cauchy-Schwarz 不等式)
- ②  $\|f + g\|_2 \leq \|f\|_2 + \|g\|_2$ ; (三角不等式)
- ③  $\|f + g\|_2^2 + \|f - g\|_2^2 = 2(\|f\|_2^2 + \|g\|_2^2)$ . (平行四边形定律)

## 函数的正交

### 定义 37 (函数正交的定义)

若  $f(x), g(x) \in C[a, b]$  满足

$$(f, g) = \int_a^b \rho(x) f(x) g(x) dx = 0$$

则称  $f(x)$  与  $g(x)$  在  $[a, b]$  上正交。若函数族:  $\varphi_0(x), \varphi_1(x), \dots, \varphi_n(x), \dots$  满足关系式

$$(\varphi_j(x), \varphi_k(x)) = \int_a^b \rho(x) \varphi_j(x) \varphi_k(x) dx = \begin{cases} 0, & j \neq k; \\ A_k \neq 0, & j = k. \end{cases}$$

则称  $\{\varphi_k(x)\}$  是  $[a, b]$  上的带权  $\rho(x)$  的正交函数族；特别，若  $A_k \equiv 1 (k = 0, 1, \dots)$ ，则称  $\{\varphi_k(x)\}$  为标准正交函数族。

## 正交函数举例

三角函数族：  $1, \cos x, \sin x, \cos 2x, \sin 2x, \dots$  是  $[-\pi, \pi]$  的正交函数族  
(权  $\rho(x) \equiv 1$ )。以下验证之。

$$(1, 1) = \int_{-\pi}^{\pi} 1 \cdot 1 dx = 2\pi, \quad (\cos nx, \sin mx) = \int_{-\pi}^{\pi} \cos nx \sin mx dx = 0.$$

$$\begin{aligned} (\sin nx, \sin mx) &= \int_{-\pi}^{\pi} \sin nx \sin mx dx, \\ &= \int_0^{\pi} \cos(n-m)x - \cos(n+m)x dx = \begin{cases} 0, & m \neq n; \\ \pi, & m = n, \end{cases} \end{aligned}$$

$$\begin{aligned} (\cos nx, \cos mx) &= \int_{-\pi}^{\pi} \cos nx \cos mx dx \\ &= \int_0^{\pi} \cos(n-m)x + \cos(n+m)x dx = \begin{cases} 0, & m \neq n; \\ \pi, & m = n. \end{cases} \end{aligned}$$

## 函数的线性无关性

### 定义 38 (函数的线性无关性定义)

设  $\varphi_0(x), \dots, \varphi_{n-1}(x) \in C[a, b]$ . 如果

$$a_0\varphi_0(x) + \dots + a_{n-1}\varphi_{n-1}(x) = 0,$$

当且仅当  $a_0 = \dots = a_{n-1} = 0$  时成立, 则称  $\varphi_0(x), \dots, \varphi_{n-1}(x)$  在  $[a, b]$  上 线性无关。

若  $\{\varphi_k(x)\} (k = 0, 1, \dots)$  中任意有限个  $\varphi_k(x)$  线性无关, 则称  $\{\varphi_k(x)\} (k = 0, 1, \dots)$  为 线性无关函数族。

## 函数线性无关的充要条件

### 定理 36 (函数线性无关的充要条件)

$\varphi_0(x), \dots, \varphi_{n-1}(x)$  在  $[a, b]$  上线性无关的充要条件是其Gram矩阵  $G_n$  非奇异。  
即

$$\det(G_n) = \begin{vmatrix} (\varphi_0, \varphi_0) & (\varphi_0, \varphi_1) & \cdots & (\varphi_0, \varphi_{n-1}) \\ (\varphi_1, \varphi_0) & (\varphi_1, \varphi_1) & \cdots & (\varphi_1, \varphi_{n-1}) \\ \cdots & \cdots & \cdots & \cdots \\ (\varphi_{n-1}, \varphi_0) & (\varphi_{n-1}, \varphi_1) & \cdots & (\varphi_{n-1}, \varphi_{n-1}) \end{vmatrix} \neq 0.$$

## 函数线性无关的充要条件

### 定理 36 (函数线性无关的充要条件)

$\varphi_0(x), \dots, \varphi_{n-1}(x)$  在  $[a, b]$  上线性无关的充要条件是其Gram矩阵  $G_n$  非奇异。  
即

$$\det(G_n) = \begin{vmatrix} (\varphi_0, \varphi_0) & (\varphi_0, \varphi_1) & \cdots & (\varphi_0, \varphi_{n-1}) \\ (\varphi_1, \varphi_0) & (\varphi_1, \varphi_1) & \cdots & (\varphi_1, \varphi_{n-1}) \\ \cdots & \cdots & \cdots & \cdots \\ (\varphi_{n-1}, \varphi_0) & (\varphi_{n-1}, \varphi_1) & \cdots & (\varphi_{n-1}, \varphi_{n-1}) \end{vmatrix} \neq 0.$$

思考如何证明，后续会给出证明。思考：如果函数  $\varphi_0(x), \dots, \varphi_{n-1}(x)$  是正交函数，它们是否线性无关？此时对应的Gram矩阵结构如何？

## 定理3.6 的证明

如果存在系数 $\alpha_0, \dots, \alpha_{n-1}$ , s.t.  $\alpha_0\varphi_0 + \dots + \alpha_{n-1}\varphi_{n-1} = 0$ , 那么该式等号两边分别用 $\varphi_0, \dots, \varphi_{n-1}$ 做内积, 可得

$$\begin{cases} \alpha_0(\varphi_0, \varphi_0) + \alpha_1(\varphi_0, \varphi_1) + \dots + \alpha_{n-1}(\varphi_0, \varphi_{n-1}) = 0, \\ \alpha_0(\varphi_1, \varphi_0) + \alpha_1(\varphi_1, \varphi_1) + \dots + \alpha_{n-1}(\varphi_1, \varphi_{n-1}) = 0, \\ \dots \\ \alpha_0(\varphi_{n-1}, \varphi_0) + \alpha_1(\varphi_{n-1}, \varphi_1) + \dots + \alpha_{n-1}(\varphi_{n-1}, \varphi_{n-1}) = 0. \end{cases}$$

这是关于 $\alpha_0, \dots, \alpha_{n-1}$ 的齐次线性方程组。由于 $\varphi_0, \dots, \varphi_{n-1}$ 线性无关 $\Leftrightarrow$ 该方程组只能有零解, 从而 $\Leftrightarrow$ 其系数行列式 $\det(G_n) \neq 0$ .

## 最佳平方逼近问题的提法

由于本节讨论在 $\|\cdot\|_2$ 也就是 $\ell_2$ 范数意义下的最佳逼近，因此我们会很自然地将最佳平方逼近问题与欧氏内积空间联系在一起。以下给出线性内积空间中的最佳平方逼近问题的提法。

### 最佳平方逼近问题

设 $\varphi_0, \dots, \varphi_n$ 是线性内积空间 $\mathcal{X}$ 的 $n + 1$ 个线性无关的元素，子空间 $\Phi = \text{span}\{\varphi_0, \varphi_1, \dots, \varphi_n\}$ . 在 $\Phi$ 中找寻找 $f \in \mathcal{X}$ 的最佳平方逼近是指寻找 $S^* \in \Phi$ , 使得 $\forall S \in \Phi$ 都有

$$\|f - S^*\|_2 \leq \|f - S\|_2.$$

## 最佳平方逼近的充要条件

### 定理3.7 子空间 $\Phi$ 中最佳平方逼近的充要条件

设 $\mathcal{X}$ 是线性内积空间,  $\varphi_0, \dots, \varphi_n$ 是 $\mathcal{X}$ 的线性无关元素。给定 $f \in \mathcal{X}$ , 则 $S^* = \sum_{i=0}^n a_i^* \varphi_i$ 是 $\Phi = \text{span}\{\varphi_0, \dots, \varphi_n\}$ 对 $f$ 的最佳平方逼近元素的充要条件是 $S^* - f$ 与所有的 $\varphi_j$ 正交, 即 $(S^* - f, \varphi_j) = 0, j = 0, 1, \dots, n$ .

## 定理3.7的证明

充分性:

$\forall S \in \Phi$ , 由于  $S^* \in \Phi$ , 因此  $(S^* - f, S - S^*) = 0$ . 于是

$$\begin{aligned}\|S - f\|_2^2 &= \|S - S^* + S^* - f\|_2^2 \\ &= ((S - S^*) + (S^* - f), (S - S^*) + (S^* - f)) \\ &= (S - S^*, S - S^*) + (S^* - f, S^* - f) \\ &= \|S - S^*\|_2^2 + \|S^* - f\|_2^2 \\ &\geq \|S^* - f\|_2^2.\end{aligned}$$

当且仅当  $S = S^*$  时, 等号成立。因此充分性得证。

必要性：用反证法证明。假设 $(f - S^*, \varphi_k), k = 0, 1, \dots, n$ 不全为零。现记 $\tilde{S} \in \Phi$ 且 $\tilde{S} - f \perp \Phi$ , 即 $(\tilde{S} - f, \varphi_k) = 0, k = 0, 1, \dots, n$ .

可以证明这样的 $\tilde{S}$ 一定存在。以下证明：

由于 $\tilde{S} \in \Phi$ , 因此

$$\tilde{S} = \sum_{i=0}^n \tilde{a}_i \varphi_i.$$

从而

$$\left( \sum_{i=0}^n \tilde{a}_i \varphi_i - f, \varphi_k \right) = 0, \quad k = 0, 1, \dots, n.$$

即

$$\left( \sum_{i=0}^n \tilde{a}_i \varphi_i, \varphi_k \right) = (f, \varphi_k), \quad k = 0, 1, \dots, n.$$

若记  $\tilde{\mathbf{a}} = (\tilde{a}_0, \tilde{a}_1, \dots, \tilde{a}_n)^T$ ,  $\mathbf{b} = ((f, \varphi_0), (f, \varphi_1), \dots, (f, \varphi_n))^T$ , 则以上方程组可以写为

$$G_{n+1}\tilde{\mathbf{a}} = \mathbf{b}.$$

这里的  $G_{n+1}$  是  $n+1$  阶 Gram 矩阵。由于  $\varphi_0, \dots, \varphi_n$  线性无关, 因此根据定理 3.6,  $G_{n+1}$  非奇异, 从而根据克莱姆法则, 该方程组解存在唯一。即  $\tilde{S}$  存在。于是  $S^* \neq \tilde{S}$  或者  $S^* - \tilde{S} \neq 0$ . 由于  $S^* - \tilde{S} \in \Phi$ , 因此  $(f - \tilde{S}, \tilde{S} - S^*) = 0$ , 从而

$$\begin{aligned}\|f - S^*\|_2^2 &= \|f - \tilde{S} + \tilde{S} - S^*\|_2^2 \\ &= \|f - \tilde{S}\|_2^2 + \|\tilde{S} - S^*\|_2^2 \\ &> \|f - \tilde{S}\|_2^2.\end{aligned}$$

这与  $S^*$  是  $f$  的最佳平方逼近函数矛盾。故假设不真, 即  $f - S^* \perp \Phi$ . 必要性得证。

## 最佳平方逼近元素存在唯一

根据以上定理3.7的结论以及证明过程可知，有以下推论

### 推论3.8 最佳平方逼近元素存在唯一

在定理3.7的条件之下的最佳平方逼近元素存在唯一。

我们称方程组

$$G_{n+1}\mathbf{a} = \begin{pmatrix} (f, \varphi_0) \\ (f, \varphi_1) \\ \vdots \\ (f, \varphi_n) \end{pmatrix} \stackrel{\text{def}}{=} \mathbf{d}$$

为法方程组 ( Normal Equations ) .

## 最佳平方逼近函数

$\forall f(x) \in C[a, b], \Phi = \text{span}\{\varphi_0, \dots, \varphi_n\} \subset C[a, b]$ . 若存在  $S^*(x) \in \Phi$ , s.t.

$$\|f - S^*\|_2^2 = \inf_{S \in \Phi} \|f - S\|_2^2 = \inf_{S \in \Phi} \int_a^b \rho(x)[f(x) - S(x)]^2 dx$$

则称  $S^*(x)$  是  $f(x)$  在  $\Phi$  上的最佳平方逼近函数。

## 最佳平方逼近多项式

特别, 取 $\varphi_k(x) = x^k (k = 0, \dots, n)$ ,  $\rho(x) \equiv 1$ ,  $f(x) \in C[a, b]$ , 则 $\Phi = \mathcal{P}_n$ ,  
而 $S^*(x) = a_0^* + a_1^*x + \dots + a_n^*x^n$ 就是 $n$ 次最佳平方逼近多项式。当 $[a, b] = [0, 1]$ 时,

$$(\varphi_j, \varphi_k) = \int_0^1 x^{j+k} dx = \frac{1}{j+k+1}, \quad (f, \varphi_k) = \int_0^1 f(x)x^k dx \stackrel{\text{def}}{=} d_k$$
$$\Rightarrow G_{n+1} = \begin{pmatrix} 1 & \frac{1}{2} & \frac{1}{3} & \cdots & \frac{1}{n+1} \\ \frac{1}{2} & \frac{1}{3} & \frac{1}{4} & \cdots & \frac{1}{n+2} \\ \frac{1}{3} & \frac{1}{4} & \frac{1}{5} & \cdots & \frac{1}{n+3} \\ \cdots & \cdots & \cdots & \cdots & \cdots \\ \frac{1}{n+1} & \frac{1}{n+2} & \frac{1}{n+3} & \cdots & \frac{1}{2n+1} \end{pmatrix} \stackrel{\text{def}}{=} H \text{—— Hilbert matrix.}$$

若记 $\mathbf{a} = (a_0, \dots, a_n)^T$ ,  $\mathbf{d} = (d_0, \dots, d_n)^T$ . 则法方程化为

$$H\mathbf{a} = \mathbf{d}.$$

注意到 $\text{cond}(H)$ 很大。直接计算以上法方程的解很困难。

## 最佳平方逼近多项式

特别, 取 $\varphi_k(x) = x^k (k = 0, \dots, n)$ ,  $\rho(x) \equiv 1$ ,  $f(x) \in C[a, b]$ , 则 $\Phi = \mathcal{P}_n$ ,  
而 $S^*(x) = a_0^* + a_1^*x + \dots + a_n^*x^n$ 就是 $n$ 次最佳平方逼近多项式。当 $[a, b] = [0, 1]$ 时,

$$(\varphi_j, \varphi_k) = \int_0^1 x^{j+k} dx = \frac{1}{j+k+1}, \quad (f, \varphi_k) = \int_0^1 f(x)x^k dx \stackrel{\text{def}}{=} d_k$$
$$\Rightarrow G_{n+1} = \begin{pmatrix} 1 & \frac{1}{2} & \frac{1}{3} & \cdots & \frac{1}{n+1} \\ \frac{1}{2} & \frac{1}{3} & \frac{1}{4} & \cdots & \frac{1}{n+2} \\ \frac{1}{3} & \frac{1}{4} & \frac{1}{5} & \cdots & \frac{1}{n+3} \\ \cdots & \cdots & \cdots & \cdots & \cdots \\ \frac{1}{n+1} & \frac{1}{n+2} & \frac{1}{n+3} & \cdots & \frac{1}{2n+1} \end{pmatrix} \stackrel{\text{def}}{=} H \text{--- Hilbert matrix.}$$

若记 $\mathbf{a} = (a_0, \dots, a_n)^T$ ,  $\mathbf{d} = (d_0, \dots, d_n)^T$ . 则法方程化为

$$H\mathbf{a} = \mathbf{d}.$$

注意到 $\text{cond}(H)$ 很大。直接计算以上法方程的解很困难。怎样克服?

## 最佳平方逼近多项式的平方误差

令  $\delta(x) = f(x) - S^*(x)$ , 则

$$\begin{aligned}\|\delta\|_2^2 &= (f - S^*, f - S^*) \\ &= (f - S^*, f) - (f - S^*, S^*) \\ &= (f - S^*, f) \\ &= (f, f) - (S^*, f) \\ &= \|f\|_2^2 - \sum_{k=0}^n a_k^*(\varphi_k, f)\end{aligned}$$

## 最佳平方逼近多项式计算举例

例. 设  $f(x) = \sqrt{1+x^2}$ , 求  $[0, 1]$  上的最佳一次平方逼近多项式。

## 最佳平方逼近多项式计算举例

例. 设  $f(x) = \sqrt{1+x^2}$ , 求  $[0, 1]$  上的最佳一次平方逼近多项式。

解:  $\varphi_0 = 1, \varphi_1 = x,$

$$d_0 = (f, \varphi_0) = \int_0^1 \sqrt{1+x^2} dx = \frac{1}{2} \ln(1+\sqrt{2}) + \frac{\sqrt{2}}{2} \approx 1.147,$$

$$d_1 = (f, \varphi_1) = \int_0^1 x\sqrt{1+x^2} dx = \frac{1}{3}(1+x^2)^{\frac{3}{2}} \Big|_0^1 = \frac{2\sqrt{2}-1}{3} \approx 0.609.$$

$$\Rightarrow \begin{pmatrix} 1 & 1/2 \\ 1/2 & 1/3 \end{pmatrix} \begin{pmatrix} a_0 \\ a_1 \end{pmatrix} = \begin{pmatrix} 1.147 \\ 0.609 \end{pmatrix} \Rightarrow \begin{cases} a_0 = 0.934 \\ a_1 = 0.426 \end{cases}$$

$$\Rightarrow S_1^*(x) = a_0 + a_1 x = 0.934 + 0.426x.$$

$$\begin{aligned} \|\delta\|_2^2 &= \|f\|_2^2 - (f, S_1^*) = \|f\|_2^2 - a_0(f, \varphi_0) - a_1(f, \varphi_1) = \|f\|_2^2 - a_0 d_0 - a_1 d_1 \\ &= \int_0^1 (1+x^2) dx - 0.934 \times 1.147 - 0.426 \times 0.609 = 0.0026 \end{aligned}$$

$$\therefore \|\delta\|_2 = 0.051. \quad (\text{对比 } \|\delta\|_\infty = \max_{0 \leq x \leq 1} |\sqrt{1+x^2} - S_1^*(x)| \approx 0.066)$$

# 第三章 函数逼近与快速Fourier变换

## 第四节 正交多项式

张振宇

上海财经大学 数学学院

## 为何使用正交多项式？

取基函数 $\varphi_k(x)$ 为 $1, x, \dots, x^n$ 寻求最佳平方逼近多项式时， $n$ 越大，条件数  $\text{cond}(G_n) = \|G_n\| \cdot \|G_n^{-1}\|$  也越大，因此法方程组是高度病态的。而解决这一问题的方法就是使用正交多项式作为基函数。

## 正交多项式的定义

### 定义 3.9 (正交多项式的定义)

设 $g_n(x)$ 是首项系数为 $a_n (\neq 0)$ 的 $n$ 次多项式。如果多项式序列 $g_0(x), g_1(x), \dots$ 满足

$$(g_j, g_k) = \int_a^b \rho(x) g_j(x) g_k(x) dx = \begin{cases} 0, & j \neq k; \\ a_k > 0, & j = k. \end{cases} \quad j, k = 0, 1, \dots$$

则称多项式序列 $g_0(x), g_1(x), \dots$ 在 $[a, b]$ 上带权 $\rho(x)$ 正交, 并称 $g_n(x)$ 是 $[a, b]$ 上带权 $\rho(x)$ 的 $n$ 次正交多项式。

## 正交化方法（长递推）的推导

利用正交化方法可以由多项式基 $\{1, x, \dots\}$ 构造出首一正交多项式 $g_0(x), g_1(x), \dots$  其中 $g_k(x) \in \mathcal{P}_k$ . 以下给出长递推的构造方法。

$\because g_k(x) \in \mathcal{P}_k, k = 0, 1, \dots \therefore$  可设 $x^n = g_n - a_{n-1}g_{n-1} - \dots - a_0g_0$  (即 $x^n$ 可以由 $g_0, \dots, g_n$ 表示。于是

$$g_n = a_0g_0 + \dots + a_{n-1}g_{n-1} + x^n.$$

由于 $(g_n, g_k) = 0, k \leq n-1$ , 因此

$$a_k = -\frac{(x^n g_k)}{(g_k, g_k)}, \quad k = 0, 1, \dots, n-1,$$

从而可得以下的长递推正交化过程。

$$g_n = x^n - \sum_{k=0}^{n-1} \frac{(x^n, g_k)}{(g_k, g_k)} g_k, \quad n = 1, 2, \dots, g_0 = 1.$$

## 短递推正交化过程

由于以上的正交化过程在求 $g_n$ 时需要用到 $g_0, \dots, g_{n-1}$ , 因此被称为“长递推”过程。由于在计算 $g_n$ 时, 需要用到 $g_n$ 前的所有正交多项式, 因此在 $n$ 比较大时, 计算量会比较大, 从而带来更多舍入误差, 最终导致多项式正交性的丢失。

## 短递推正交化过程

由于以上的正交化过程在求 $g_n$ 时需要用到 $g_0, \dots, g_{n-1}$ , 因此被称为“长递推”过程。由于在计算 $g_n$ 时, 需要用到 $g_n$ 前的所有正交多项式, 因此在 $n$ 比较大时, 计算量会比较大, 从而带来更多舍入误差, 最终导致多项式正交性的丢失。

短递推正交化过程在计算 $g_n$ 时仅用到 $g_{n-1}, g_{n-2}$ , 因此可以避免多项式正交性过早丢失这一问题。以下给出多项式的短递推正交化过程的推导。

## 短递推过程的推导

$\because xg_n \in \mathcal{P}_{n+1}, \therefore xg_n$ 可以由 $g_0, \dots, g_{n+1}$ 线性表示, 即

$$xg_n = a_0g_0 + \cdots + a_{n-1}g_{n-1} + a_ng_n + g_{n+1}.$$

于是 $(xg_n, g_k) = a_k(g_k, g_k), k = 0, \dots, n$ , 又因为

$$\begin{aligned}(xg_n, g_k) &= \int_a^b \rho(x)xg_ng_k dx = \int_a^b \rho(x)g_n(xg_k) dx \\ &= (g_n, xg_k) \begin{cases} = 0, & k < n-1; \\ \neq 0, & k \geq n-1. \end{cases}\end{aligned}$$

故只能 $a_k = 0, k = 0, \dots, n-2$ . 这样 $xg_n = a_{n-1}g_{n-1} + a_ng_n + g_{n+1}$ . 从而得到短递推公式

$$g_{n+1} = (x - a_n)g_n - a_{n-1}g_{n-1}, \quad n = 0, 1, \dots, g_0 = 1, g_{-1} = 0.$$

## 短递推公式中系数 $a_{n-1}, a_n$ 的推导

为了能区分长短递推公式的系数，将短递推公式改写为

$$g_{n+1} = (x - \alpha_n)g_n - \beta_n g_{n-1}, \quad n = 0, 1, \dots, g_0 = 1, g_{-1} = 0.$$

上式两边分别与 $g_n, g_{n-1}$ 作内积可得

$$\alpha_n = \frac{(xg_n, g_n)}{(g_n, g_n)}, \quad \beta_n = \frac{(xg_n, g_{n-1})}{(g_{n-1}, g_{n-1})}.$$

因 $(xg_n, g_{n-1}) = (g_n, xg_{n-1})$ ，又因为 $xg_{n-1} \in \mathcal{P}_n$ ，

$$xg_{n-1} = g_n + b_{n-1}g_{n-1} + \cdots + b_1g_1 + b_0,$$

故 $(xg_{n-1}, g_n) = (g_n, g_n)$ ，从而

$$\beta_n = \frac{(g_n, g_n)}{(g_{n-1}, g_{n-1})}.$$

## 正交多项式的性质

总结以上推导的结果，可以给出以下的正交多项式的性质：

- ① 正交多项式 $g_n$ 都是首一多项式；
- ②  $\forall P_n(x) \in \mathcal{P}_n$ , 都可以表示为 $g_k(x), k = 0, \dots, n$ 的线性组合，从而可知 $g_n$ 与任何次数小于 $n$ 的多项式正交，即 $(g_n, P(x)) = 0, P(x) \in \mathcal{P}_{n-1}$ ；
- ③ 当 $n \neq m$ 时， $(g_n, g_m) = 0$ ；
- ④ 设 $\{g_k(x)\} (k = 0, 1, \dots)$ 是 $[a, b]$ 上带权 $\rho(x)$ 的正交多项式序列，则 $g_n(x) (n \geq 1)$ 的 $n$ 个根都是单重实根，且都在 $(a, b)$ 内。

## 第4条性质的证明

若 $g_n(x)$ 在 $(a, b)$ 内的根都是偶数重的, 则 $g_n(x)$ 在 $[a, b]$ 上的符号保持不变。但这与

$$(g_n, g_0) = \int_a^b \rho(x) g_n(x) \cdot 1 dx = 0$$

矛盾。故 $g_n(x)$ 在 $(a, b)$ 内的根不可能全是偶数重的。现设 $g_n(x)$ 在 $(a, b)$ 共有 $r$ 个奇数重根:  $x_i, i = 1, \dots, r$ , 令 $h(x) = (x - x_1) \cdots (x - x_r)$ , 于是 $g_n(x)h(x)$ 在 $[a, b]$ 上符号保持不变, 则

$$(g_n, h) = \int_a^b \rho(x) g_n(x) h(x) dx \neq 0.$$

若 $r < n$ , 则由正交多项式第2条性质可知 $(g_n, h) = 0$ , 因此只能 $r \geq n$ , 但 $g_n(x)$ 最多只有 $n$ 个根, 故 $g_n(x)$ 的零点都是单重的, 且都在 $(a, b)$ 内。

## 两种常用的正交多项式

选取不同的区间 $[a, b]$ 和权函数 $\rho(x)$ ，会得到不同的正交多项式。以下我们讨论两种常用的正交多项式：Legendre正交多项式和Chebyshev正交多项式。

## Legendre正交多项式

取 $[a, b] = [-1, 1]$ ,  $\rho(x) \equiv 1$ , 由 $\{1, x, \dots, x^n, \dots\}$ 正交化得到的正交多项式称为Legendre正交多项式, 用 $P_0(x), P_1(x), \dots, P_n(x), \dots$ 表示, 其中

$$P_0(x) = 1, P_n(x) = \frac{1}{2^n n!} \frac{d^n}{dx^n} [(x^2 - 1)^n], n = 1, 2, \dots$$

$P_n(x)$ 的首项系数

$$a_n = \frac{1}{2^n n!} (2n)(2n-1) \cdots (2n-n+1) = \frac{1}{2^n n!} \cdot \frac{(2n)!}{n!} = \frac{(2n)!}{2^n (n!)^2}.$$

于是, 首一的Legendre正交多项式为

$$\tilde{P}_n = \frac{2^n (n!)^2}{(2n)!} P_n(x) = \frac{2^n (n!)^2}{(2n)!} \cdot \frac{1}{2^n n!} \frac{d^n}{dx^n} [(x^2 - 1)^n] = \frac{n!}{(2n)!} \frac{d^n}{dx^n} [(x^2 - 1)^n].$$

## Legendre正交多项式的性质

既然Legendre正交多项式也是从多项式基函数 $1, x, x^2, \dots$ 正交化而来的，那么其性质大多来自于前面推导的正交多项式的性质。但是也有其特有的性质。

① 正交性。

$$\int_{-1}^1 P_n(x)P_m(x)dx = \begin{cases} 0, & m \neq n; \\ \frac{2}{2n+1}, & m = n. \end{cases}$$

② 奇偶性:  $P_n(-x) = (-1)^n P_n(x)$ .

记 $\varphi(x) = (x^2 - 1)^n$ 是偶次多项式（每一项都是偶次幂项的多项式），故当 $n$ 为偶数时， $\varphi^{(n)}(x)$ 仍为偶次多项式；当 $n$ 为奇数时， $\varphi^{(n)}(x)$ 为奇次多项式，从而 $P_n(x)$ 的奇偶性与 $n$ 相同。

③ 递推关系：请大家也思考一下如何直接从前面一般的正交多项式的递推关系来推导。

$$(n+1)P_{n+1} = (2n+1)xP_n - nP_{n-1}, n = 1, 2, \dots; P_0 = 1, P_1 = x.$$

④ 在所有首一 $n$ 次多项式中，Legendre多项式 $\tilde{P}_n(x)$ 在 $[-1, 1]$ 上与零的平方误差最小。

⑤  $P_n(x)$ 在 $(-1, 1)$ 内有 $n$ 个不同的零点。

## Legendre正交多项式性质4的证明

设 $p(x) \in \mathcal{P}_n$ 是任一给定的 $n$ 次首一多项式, 则 $p(x)$ 可以由 $\tilde{P}_0, \tilde{P}_1, \dots, \tilde{P}_n$ 线性表示, 即

$$p(x) = \tilde{P}_n + \sum_{k=0}^{n-1} c_k \tilde{P}_k.$$

于是

$$\begin{aligned} \|p(x) - 0\|_2^2 &= \|p(x)\|_2^2 = (p(x), p(x)) \\ &= (\tilde{P}_n, \tilde{P}_n) + \sum_{k=0}^{n-1} |c_k|^2 (\tilde{P}_k, \tilde{P}_k) \\ &= \|\tilde{P}_n\|_2^2 + \sum_{k=0}^{n-1} |c_k|^2 \|\tilde{P}_k\|_2^2 \\ &\geq \|\tilde{P}_n\|_2^2. \end{aligned}$$

## Chebyshev正交多项式的定义

若取 $\rho(x) = \frac{1}{\sqrt{1-x^2}}$ ,  $[a, b] = [-1, 1]$ , 则从 $\{1, x, \dots, x^n, \dots\}$ 正交化所得的正交多项式称为Chebyshev正交多项式。它可以表示为

$$T_n(x) = \cos(n \arccos x), \quad |x| \leq 1.$$

若令 $x = \cos \theta$ , 则

$$T_n(x) = \cos n\theta, \quad 0 \leq \theta \leq \pi.$$

## Chebyshev多项式的性质

① 递推关系:

$$T_0(x) = 1, T_1(x) = x, T_{n+1}(x) = 2xT_n(x) - T_{n-1}(x), \quad n = 1, 2, \dots$$

②  $T_n(x)$ 与零的偏差最小。

### 定理 3.9 (Chebyshev多项式的最小偏差性)

在 $[-1, 1]$ 上, 首一的 $n$ 次多项式中,  $\tilde{T}_n(x) = \frac{1}{2^{n-1}}T_n(x)$ 与零的偏差最小, 为 $\frac{1}{2^{n-1}}$ . (证明稍后给出)

例、求 $f(x) = 2x^3 + x^2 + 2x - 1$ 在 $[-1, 1]$ 上的最佳二次逼近多项式 $P_2^*(x)$ .

解: 由于 $f(x) - P_2^*(x) \in \mathcal{P}_3$ , 且  $\max_{-1 \leq x \leq 1} |f(x) - P_2^*(x)| = \min$ , 因此可以认为 $\frac{1}{2}[f(x) - P_2^*(x)]$ 在 $[-1, 1]$ 上与零的偏差最小。因此

$$\frac{1}{2}[f(x) - P_2^*(x)] = \frac{1}{2^{3-1}}T_3 \Rightarrow P_2^*(x) = x^2 + \frac{7}{2}x - 1.$$

## Chebyshev多项式的性质 (续)

- ③ Chebyshev多项式 $\{T_n(x)\}$ 在 $[-1, 1]$ 上带权 $\rho(x) = \frac{1}{\sqrt{1-x^2}}$ 正交, 且

$$(T_n, T_m) = \int_{-1}^1 \frac{T_n(x)T_m(x)}{\sqrt{1-x^2}} dx = \begin{cases} 0, & m \neq n; \\ \frac{\pi}{2}, & m = n \neq 0; \\ \pi, & m = n = 0. \end{cases}$$


作变量替换:  $x = \cos \theta, dx = -\sin \theta d\theta$ 可证。

- ④  $T_{2k}(x)$ 只含有 $x$ 的偶次幂,  $T_{2k+1}(x)$ 只含有 $x$ 的奇次幂。

利用递推关系式 $T_{n+1}(x) = 2xT_n(x) - T_{n-1}(x), T_0(x) = 1, T_1(x) = x$ 可证。

- ⑤  $T_n(x) = \cos n \arccos x$ 在 $[-1, 1]$ 上的 $n$ 个零点 $\cos \frac{2k-1}{2n}\pi, k = 1, \dots, n$ 和 $n+1$ 个极值点 $\cos \frac{k}{n}\pi, k = 0, 1, \dots, n$ , 共 $2n+1$ 个点称为Chebyshev点。它们在单位圆周上等距分布, 在 $[-1, 1]$ 端点处密集分布。(见下图)

## Chebyshev多项式的性质（续）



## 定理3.9的证明

根据Chebyshev多项式的递推关系可知:  $T_n(x)$ 的首项系数为 $2^{n-1}$ . 因此,  $\tilde{T}_n(x) = \frac{1}{2^{n-1}}T_n(x)$ 是首项系数为1的Chebyshev多项式. 故可设

$$\tilde{T}_n(x) = x^n - p_{n-1}^*(x), \quad p_{n-1}^*(x) \in \mathcal{P}_{n-1}.$$

根据Chebyshev多项式的第5个性质:  $\tilde{T}_n(x)$ 在 $[-1, 1]$ 有 $n + 1$ 个轮流取正负的极值点 $x_k = \cos \frac{k}{n}\pi, k = 0, 1, \dots, n$ , 因此等同于 $p_{n-1}^*(x)$ 与 $x^n$ 有 $n + 1$ 个轮流取正负的偏差点. 从而根据定理3.4 (Chebyshev逼近定理) 可知,  $p_{n-1}^*(x)$ 是 $x^n$ 的 $n - 1$ 次最佳逼近多项式. 从而满足:

$$\|\tilde{T}_n(x) - 0\|_\infty = \min_{p(x) \in \mathcal{P}_{n-1}} \|x^n - p(x)\|_\infty = \min_{p(x) \in \mathcal{P}_n \text{ 且 } p(x) \text{ 首一}} \|p(x)\|_\infty.$$

## 利用Chebyshev多项式计算近似最佳逼近多项式

在3.2节中，我们曾通过计算一次最佳逼近多项式的算例告诉大家，计算精确的最佳逼近多项式是比较困难的。因此我们常常会计算近似最佳逼近多项式。以下给出三个计算近似最佳逼近多项式的方法：

- ① 截断Chebyshev级数；
- ② Lagrange插值余项极小化（即利用Chebyshev多项式零点极小化插值余项）；
- ③ Taylor级数项数节约。

我们分别予以介绍。

## 截断Chebyshev级数

设  $[a, b] = [-1, 1]$ ,  $f(x) \in \mathbb{C}[-1, 1]$ 。把  $f(x)$  展开成  $\{\varphi_k(x)\}_0^\infty$  的广义Fourier级数, 其中  $\{\varphi_k(x)\}_0^\infty$  取成 Chebyshev 多项式  $\{T_k(x)\}_0^\infty$ , 即

$$f(x) \sim \frac{C_0^*}{2} + \sum_{k=1}^{\infty} C_k^* T_k(x)$$

其中展开系数  $C_k^* (k = 0, 1, \dots)$  可根据下式来计算

$$C_k^* = \frac{2}{\pi} \int_{-1}^1 \frac{f(x) T_k(x)}{\sqrt{1-x^2}} dx, \quad k = 0, 1, \dots$$

称  $\frac{C_0^*}{2} + \sum_{k=1}^{\infty} C_k^* T_k(x)$  为  $f(x)$  的 Chebyshev 级数。

若令 $x = \cos \theta, 0 \leq \theta \leq \pi$ , 则很显然Chebyshev级数就变成了 $f(\cos \theta)$ 的Fourier级数了, 且其系数为

$$C_k^* = \frac{2}{\pi} \int_0^\pi f(\cos \theta) \cos k\theta d\theta$$

根据Fourier级数理论可知: 当 $f''(x)$ 在 $[-1, 1]$ 上分段连续, 则 $f(x)$ 的Chebyshev级数一致收敛于 $f(x)$ 。故此时

$$f(x) = \frac{C_0^*}{2} + \sum_{k=1}^{\infty} C_k^* T_k(x)$$

取其部分和

$$C_n^*(x) = \frac{C_0^*}{2} + \sum_{k=1}^n C_k^* T_k(x)$$

利用 $C_n^*(x)$ 逼近 $f(x)$ 的误差为

$$|f(x) - C_n^*(x)| = \left| \sum_{k=n+1}^{\infty} C_k^* T_k(x) \right| \approx |C_{n+1}^* T_{n+1}(x)|$$

由于 $T_{n+1}(x)$ 有 $n + 2$ 个轮流取“正”、“负”的偏差点:

$$x_k = \cos \frac{k\pi}{n+1}, \quad k = 0, 1, \cdots, n+1.$$

故 $f(x) - C_n^*(x)$ 近似地也有 $n + 2$ 个偏差点。由 Chebyshev 逼近定理,  $C_n^*(x)$  可以作为  $f(x)$  在  $[-1, 1]$  上的近似最佳一致逼近多项式。

## 截断Chebyshev级数举例

例、利用Chebyshev多项式计算 $f(x) = e^x$ 在 $[-1, 1]$ 上的三次近似最佳一致逼近多项式 $C_3^*(x)$ .

解：由前述的推导可知： $c_k^* = \frac{\pi}{2} \int_0^\pi e^{\cos \theta} \cos k\theta d\theta, k = 0, 1, 2, 3$ . 采用数值积分的方法可得

$$c_0^* = 2/53212176, c_1^* = 1.13031821,$$

$$c_2^* = 0.27149534, c_3^* = 0.04433685.$$

从而可得

$$C_3^* = 0.994531 + 0.997308x + 0.542991x^2 + 0.177347x^3,$$

$$\|e^x - C_3^*\|_\infty \approx 0.00607.$$

思考，区间 $[a, b] \neq [-1, 1]$ 怎么处理？大家可以对 $f(x) = e^x, x \in [0, 1]$ 编制程

序，计算其近似三次最佳逼近多项式。从算例的实际计算过程和结果来看，其计算过程较为简单且效果不错。

## Chebyshev多项式零点的插值余项最小化

若选用上述的Chebyshev多项式 $T_{n+1}(x)$ 的 $n + 1$ 个零点 $\cos \frac{2k-1}{2n+2}\pi, k = 1, \dots, n + 1$ 作为插值节点, 对应的插值多项式记为 $L_n(x)$ , 则当被插函数 $f \in C^{n+1}[-1, 1]$ 时, 其插值余项为

$$R_n(x) = \frac{f^{(n+1)}(\xi)}{(n+1)!} \omega_{n+1}(x) = \frac{f^{(n+1)}(\xi)}{(n+1)!} \tilde{T}_{n+1}(x),$$

$$\max_{-1 \leq x \leq 1} |R_n(x)| \leq \frac{\max_{-1 \leq x \leq 1} |f^{(n+1)}(x)|}{(n+1)!} \max_{-1 \leq x \leq 1} |\tilde{T}_{n+1}(x)| \stackrel{\text{def}}{=} \frac{M_{n+1}}{(n+1)!} 2^{-n}.$$

即插值余项最小化。

这样得到的 $L_n(x)$ 由于不一定满足Chebyshev逼近定理 ( 即 $f(x) - L_n(x)$ 不一定有 $n + 2$ 个轮流取正负的偏差点 ), 故不可作为最佳一致逼近多项式。但由于其误差分布均匀, 因此可以作为近似最佳一致逼近多项式。

## 利用Chebyshev多项式零点插值举例

例、求  $f(x) = e^x$  在  $[0, 1]$  上的4次Lagrange插值多项式  $L_4(x)$ , 插值节点用  $T_5(x)$  的零点, 并估计误差  $\max_{0 \leq x \leq 1} |e^x - L_4(x)|$ .

解:  $T_5(t) = 16t^5 - 20t^3 + 5, t \in [-1, 1]$ . 需要进行变量代换转换到  $[0, 1]: x = \frac{1}{2}(t + 1)$ .

$T_5(t)$  的5个零点:  $t_k = \cos \frac{2k+1}{10}\pi, k = 0, \dots, 4$ . 则经变量代换转换后对

应  $T_5(x) = 16(2x - 1)^5 - 20(2x - 1)^3 + 5$  的5个零点为:  $x_k = \frac{1}{2}(1 + \cos \frac{2k+1}{10}\pi, k = 0, \dots, 4)$ .

记  $y_k = e^{x_k}$ , 则利用插值条件  $L_4(x_k) = y_k, k = 0, \dots, 4$  可以计算出Lagrange插值多项式  $L_4(x)$ :

$$L_4(x) = 0.06942x^4 + 0.14028x^3 + 0.50978x^2 + 0.99876x + 1.00002.$$

$$\begin{aligned} \max_{0 \leq x \leq 1} |e^x - L_4(x)| &= \max_{0 \leq x \leq 1} \frac{e^x}{5!} \prod_{k=0}^4 (x - x_k) \leq \frac{e}{5!} \max_{-1 \leq t \leq 1} \prod_{k=0}^4 \left[ \frac{1}{2}(t - t_k) \right] \\ &\leq \frac{e}{120} \frac{1}{2^5} \frac{1}{2^4} \approx 4.42 \times 10^{-5}. \end{aligned}$$

可对Runge现象中的函数使用Chebyshev零点插值, 并观察是否出现Runge现象。

## Taylor 级数项数节约

如果用函数在某点的Taylor展开来逼近该函数，则为了提高逼近精度，往往不得不取较多的展开项数。但考虑到高次多项式对函数逼近的不稳定性，我们一般不会这样做。但利用Chebyshev多项式表示 $x^k (k = 0, 1, \dots)$ 这一性质对函数 $f(x)$ 的Taylor展开式

$$P_n(x) = a_0 + a_1x + \dots + a_nx^n \approx f(x)$$

进行重新组合

$$P_n(x) = b_0 + b_1T_1(x) + \dots + b_nT_n(x) \quad (2.2.1)$$

（其实这就是函数的Chebyshev级数展开）可以发现随着下标 $k$ 的增大，其系数 $b_k$ 的绝对值越来越小。又因为 $|T_k(x)| \leq 1$ ，故我们可以略去次数高的 $T_k(x)$ ，这就意味着降低了逼近多项式的次数。从而也可以得到逼近效果令人满意的近似最佳一致逼近多项式。这就是所谓的Taylor级数项数节约方法。

## Taylor 级数项数节约举例

我们仍旧以函数  $f(x) = e^x$  为例，考虑  $x \in [-1, 1]$  时的近似最佳一致逼近多项式。  
对  $f(x) = e^x$  进行Maclaurin展开到  $x^6$ ：

$$f(x) = 1 + x + \frac{1}{2}x^2 + \frac{1}{6}x^3 + \frac{1}{24}x^4 + \frac{1}{120}x^5 + \frac{1}{720}x^6 + O(x^6) = P_6(x) + O(x^6)$$

其误差为：

$$\max_{-1 \leq x \leq 1} |e^x - P_6(x)| \leq \frac{e}{7!} x^7 < 5.3934 \times 10^{-4}$$

而

$$\begin{aligned} T_6(x) &= 32x^6 - 48x^4 + 18x^2 - 1 \\ T_5(x) &= 16x^5 - 20x^3 + 5x \end{aligned}$$

因此

$$\begin{aligned}x^6 &= \frac{1}{32}T_6(x) + \frac{3}{2}x^4 - \frac{9}{16}x^2 + \frac{1}{32} \\x^5 &= \frac{1}{16}T_5(x) + \frac{5}{4}x^3 - \frac{5}{16}x\end{aligned}$$

把以上结果代入 $P_6(x)$ 中, 可得

$$P_6(x) = M_{6,4}(x) + \frac{1}{120} \cdot \frac{1}{16}T_5(x) + \frac{1}{720} \cdot \frac{1}{32}T_6(x)$$

其中,  $M_{6,4}(x)$ 与 $f(x)$ 的误差为

$$\max_{-1 \leq x \leq 1} |e^x - M_{6,4}(x)| \leq 0.0011$$

若再用 $x^4 = \frac{1}{8}T_4(x) + x^2 - \frac{1}{8}$ 代入 $M_{6,4}(x)$ 可以求出 $M_{6,3}(x)$ , 其逼近误差为

$$\max_{-1 \leq x \leq 1} |e^x - M_{6,3}(x)| \leq 0.00651$$

这个逼近效果已经接近 $e^x$ 的截断Chebyshev级数近似最佳一致逼近多项式 $C_3^*(x)$ 了。若从 $f(x)$ 的7次, 8次Taylor展开式 $P_7(x)$ ,  $P_8(x)$ 或者更高次的展开式出发求出 $M_{7,3}(x)$ ,  $M_{8,3}(x)$ , 将得到更接近最佳一致逼近多项式的结果。也就是说利用Taylor级数项数节约的方法求近似最佳一致逼近多项式时, 开始项数越多, 效果越显著。经过重新改组的Taylor展开式, 其误差分布均匀, 也可作为近似最佳一致逼近多项式。

## 其他的常用正交多项式

1. 第二类Chebyshev多项式:  $[a, b] = [-1, 1], \rho(x) = \sqrt{1 - x^2}$ .

$$U_n(x) = \frac{\sin[(n+1)\arccos x]}{\sqrt{1-x^2}}, (U_n, U_m) = \begin{cases} 0, & m \neq n \\ \frac{\pi}{2}, & m = n. \end{cases}$$

$$U_0(x) = 1, U_1(x) = 2x, U_{n+1}(x) = 2xU_n(x) - U_{n-1}(x), n = 1, 2, \dots$$

2. Laguerre多项式:  $[a, b] = [0, +\infty), \rho(x) = e^{-x}$ .

$$L_n(x) = e^x \frac{d^n}{dx^n} (x^n e^{-x}), (L_n, L_m) = \begin{cases} 0, & m \neq n \\ (n!)^2, & m = n. \end{cases}$$

$$L_0(x) = 1, L_1(x) = 1 - x, L_{n+1}(x) = (1 + 2n - x)L_n(x) - n^2 L_{n-1}(x).$$

## 其他的常用正交多项式（续）

3. Hermite多项式:  $[a, b] = (-\infty, \infty)$ ,  $\rho(x) = e^{-x^2}$ .

$$H_n(x) = (-1)^n e^{x^2} \frac{d^n}{dx^n}(e^{-x^2}), (H_n, H_m) = \begin{cases} 0, & m \neq n \\ 2^n n! \sqrt{\pi}, & m = n. \end{cases}$$

$$H_0(x) = 1, H_1(x) = 2x, H_{n+1}(x) = 2xH_n(x) - 2nH_{n-1}(x), n = 1, 2, \dots$$

## 使用正交函数族作最佳平方逼近

设  $f(x) \in C[a, b]$ ,  $\Phi = \text{span}\{\varphi_0(x), \dots, \varphi_n(x)\}$ . 若  $\{\varphi_k\}_{k=0}^n$  是正交函数族, 满足  $(\varphi_k, \varphi_l) = 0, k \neq l, (\varphi_k, \varphi_k) > 0, k, l = 0, \dots, n$ . 记  $S^*(x) = \sum_{k=0}^n a_k^* \varphi_k$  是  $f$  在  $\Phi$  中的最佳平方逼近函数, 其系数构成的向量  $\mathbf{a} = (a_0^*, \dots, a_n^*)^T$  满足法方程

$$G_{n+1} \mathbf{a} = \mathbf{d},$$

其中

$$G_{n+1} = (g_{ij}), g_{ij} = ((\varphi_{i-1}, \varphi_{j-1})), \mathbf{d} = (d_j), d_j = (f, \varphi_{j-1}), i, j = 1, \dots, n+1.$$

由  $\{\varphi_k\}$  的正交性可知:  $G_{n+1} = \text{diag}((\varphi_0, \varphi_0), \dots, (\varphi_n, \varphi_n))$ , 从而

$$a_k^* = \frac{d_{k+1}}{(\varphi_k, \varphi_k)} = \frac{(f, \varphi_k)}{\|\varphi_k\|_2^2}, S^*(x) = \sum_{k=0}^n a_k^* \varphi_k = \sum_{k=0}^n \frac{(f(x), \varphi_k(x))}{\|\varphi_k(x)\|_2^2} \varphi_k(x), k = 0, \dots, n.$$

## 最佳平方逼近函数的平方逼近误差

设 $f(x)$ 的最佳平方逼近函数为 $S^*(x)$ ，则其平方逼近误差

$$\begin{aligned}\|\delta(x)\|_2 &= \|f(x) - S^*(x)\| = \sqrt{(f - S^*, f - S^*)} \\&= \sqrt{(f, f) - (f, S^*) + (S^*, S^* - f)} \\&= \sqrt{(f, f) - (S^*, f)} \\&= \left( \|f\|_2^2 - \sum_{k=0}^n \left[ \frac{(f, \varphi_k)}{\|\varphi_k\|_2} \right]^2 \right)^{\frac{1}{2}} \\&= \left( \|f\|_2^2 - \sum_{k=0}^n \left[ \frac{(f, \varphi_k)}{\|\varphi_k\|_2^2} \right]^2 \|\varphi_k\|_2^2 \right)^{\frac{1}{2}} = \left[ \|f\|_2^2 - \sum_{k=0}^n (a_k^* \|\varphi_k\|_2)^2 \right]^{\frac{1}{2}}\end{aligned}$$

## 使用正交多项式作最佳平方逼近及其误差

考虑  $f(x) \in C[-1, 1]$ , 正交多项式族取为Legendre多项式  $\{P_k(x)\}_{k=0}^n$ . 则

$$S^*(x) = \sum_{k=0}^n a_k^* P_k(x),$$

其中

$$a_k^* = \frac{(f, P_k)}{\|P_k\|_2^2} = \frac{2k+1}{2} \int_{-1}^1 f(x) P_k(x) dx,$$

其平方误差的平方为

$$\|\delta\|_2^2 = \|f\|_2^2 - \sum_{k=0}^n a_k^{*2} \|P_k\|_2^2 = \int_{-1}^1 f^2(x) dx - \sum_{k=0}^n \frac{2}{2k+1} a_k^{*2}.$$

注: 由于  $\text{span}\{1, x, \dots, x^n\} = \text{span}\{P_0, P_1, \dots, P_n\} = \mathcal{P}_n$ , 因此利用Legendre正交多项式得到的最佳平方逼近多项式与直接求解系数矩阵为  $H_{n+1}$  的法方程所得的最佳平方逼近多项式相同, 但在  $n$  较大时后者的问题是病态问题。

## 求最佳平方逼近多项式举例

例、求  $f(x) = e^x$  在  $[-1, 1]$  上的三次最佳平方逼近多项式。

解：

$$(f, P_0) = \int_{-1}^1 e^x dx \approx 2.3504, \quad (f, P_1) = \int_{-1}^1 x e^x dx \approx 0.7358$$

$$(f, P_2) = \int_{-1}^1 \left( \frac{3}{2}x^2 - \frac{1}{2} \right) e^x dx \approx 0.1431, \quad (f, P_3) = \int_{-1}^1 \left( \frac{5}{2}x^3 - \frac{3}{2}x \right) e^x dx \approx 0.0201.$$

$$a_0^* = \frac{(f, P_0)}{2} = 1.1752, \quad a_1^* = \frac{3(f, P_1)}{2} = 1.1036,$$

$$a_2^* = \frac{5(f, P_2)}{2} = 0.3578, \quad a_3^* = \frac{7(f, P_3)}{2} = 0.0705.$$

$$S^*(x) = \sum_{k=0}^3 a_k^* P_k = 0.9963 + 0.9979x + 0.5367x^2 + 0.1761x^3.$$

$$\|\delta\|_2 = \sqrt{\int_{-1}^1 e^{2x} dx - \sum_{k=0}^3 \frac{2}{2k+1} a_k^{*2}} \approx 0.0084.$$



# 第三章 函数逼近与快速Fourier变换

## 第五节 曲线拟合的最小二乘法

张振宇

上海财经大学 数学学院

## 何为曲线拟合

给定实验数据 $(x_i, y_i), i = 0, 1, \dots, m$ , 其中 $y_i = f(x_i)$ , 但 $f(x)$ 未知。所谓曲线拟合是指：寻找函数 $S^*(x)$ 与所给实验数据拟合。记

$$\boldsymbol{\delta} = (\delta_0, \dots, \delta_m)^T, \delta_i = S^*(x_i) - y_i, i = 0, 1, \dots, m.$$

设 $\{\varphi_k(x)\}_{k=0}^n$ 是 $C[a, b]$ 上的线性无关函数族。所谓 $S^*(x)$ 与所给实验数据拟合是指寻找 $S^*(x) \in \Phi = \text{span}\{\varphi_0, \dots, \varphi_n\}$ , s.t.

$$\|\boldsymbol{\delta}\|_2^2 = \sum_{i=0}^m \delta_i^2 = \sum_{i=0}^m [S^*(x_i) - y_i]^2 = \min_{S(x) \in \Phi} \sum_{i=0}^m [S(x_i) - y_i]^2.$$

## 关于曲线拟合问题的两点说明

- ① 首先，要确定 $S^*$ 的形式（或称为数学模型），即基函数 $\{\varphi_k(x)\}_{k=0}^n$ 的数量与形式。这与问题本身有关！
- ②  $\|\delta\|_2^2$ 通常须考虑加权和，即

$$\|\delta\|_2^2 = \sum_{i=0}^m \omega(x_i) [S^*(x_i) - y_i]^2.$$

其中， $\omega(x)$ 是权函数，表示不同数据点的比重。比如 $\omega(x_i)$ 可以表示观测点 $(x_i, y_i)$ 被观测到的次数等。

在确定了权函数和基函数以后，可以求 $S^*(x)$ 。以下给出用最小二乘法求进行曲线拟合的推导。

## 最小二乘法推导

设 $S(x) = a_0\varphi_0(x) + \cdots + a_n\varphi_n(x)$ , 求 $S^*(x) = a_0^*\varphi_0(x) + \cdots + a_n^*\varphi_n(x)$ 的系数 $a_k^*$ ,  $k = 0, \dots, n$ 的过程与最佳平方逼近函数的计算过程相同。若定义向量内积:

$$(\varphi_k, \varphi_l) = \sum_{i=0}^m \omega(x_i) \varphi_k(x_i) \varphi_l(x_i), k, l = 0, \dots, n.$$

其中,  $\varphi_k = (\varphi_k(x_0), \dots, \varphi_k(x_m))^T$ . 则可得法方程 $G\mathbf{a} = \mathbf{d}$ . 其中

$$G = \begin{pmatrix} (\varphi_0, \varphi_0) & \cdots & (\varphi_0, \varphi_n) \\ \vdots & & \vdots \\ (\varphi_n, \varphi_0) & \cdots & (\varphi_n, \varphi_n) \end{pmatrix}, \mathbf{a} = (a_0, \dots, a_n)^T,$$

$\mathbf{d} = ((\mathbf{f}, \varphi_0), \dots, (\mathbf{f}, \varphi_n))^T$ ,  $\mathbf{f} = (y_0, \dots, y_n)^T$ . 法方程的解 $\mathbf{a}^* = (a_0^*, \dots, a_n^*)^T$ 就是 $S^*(x)$ 的系数。

## 解的存在唯一性

由于内积定义的变化,  $\{\varphi_k(x)\}_{k=0}^n$  线性无关并不能保证  $\det(G) \neq 0$ .

比如,  $n = 1, \varphi_0(x) = \sin x, \varphi_1(x) = \sin 2x$ . 由于  $\varphi_1(x)/\varphi_0(x) \neq 0$ , 故  $\varphi_0, \varphi_1$  线性无关. 但若取  $m = 2, x_i = i\pi, i = 0, 1, 2$ , 则  $\varphi_0(x_i) = \varphi_1(x_i) = 0, i = 0, 1, 2$ , 此时, 无论权函数  $\omega(x)$  怎么取, 都有  $G = 0$ . 为了保证法方程的系数矩阵非奇异 (否则解做不到存在唯一), 给出以下的Haar条件:

### 定义 3.10 (Haar条件)

设  $\varphi_k(x) \in C[a, b] (k = 0, \dots, n)$  的任意线性组合在点集  $\{x_i, i = 0, 1, \dots, m\} (m \geq n)$  至多只有  $n$  个不同的零点, 则称  $\varphi_k(x) (k = 0, \dots, n)$  在点集  $\{x_i, i = 0, 1, \dots, m\}$  上满足 Haar条件.

## 解的存在唯一性 (续)

可以证明：只要基函数 $\varphi_k(x)$  ( $k = 0, \dots, n$ ) 在 $x_i, i = 0, 1, \dots, m$ 上满足Haar条件, 则 $\det(G) \neq 0$ , 例如 $\varphi_k(x)$ 取为多项式基 $1, x, \dots, x^n$ . 此时法方程一定有唯一解 $\mathbf{a}^*$ .

再使用与推导最佳平方逼近函数平方误差最小的过程类似的方法可以证明：

$$\sum_{i=0}^m \omega(x_i) [S^*(x_i) - f(x_i)]^2 \leq \sum_{i=0}^m \omega(x_i) [S(x_i) - f(x_i)]^2, \forall S(x) \in \Phi.$$

从而得到 $S^*(x) = a_0^* \varphi_0(x) + \dots + a_n^* \varphi_n(x)$ 的确是所求的最小二乘解.

从以上的推导可以看出，应用最小二乘法求解曲线拟合问题主要应考虑以下两点：

- 根据给定的数据 $(x_i, y_i)$ , 确定合适的基函数（即确定数学模型）；
- 尽量避免法方程系数矩阵 $G$ 的病态。

## 曲线拟合问题举例一

例、已知一组实验数据：

|            |   |     |   |   |     |
|------------|---|-----|---|---|-----|
| $x_i$      | 1 | 2   | 3 | 4 | 5   |
| $f_i$      | 4 | 4.5 | 6 | 8 | 8.5 |
| $\omega_i$ | 2 | 1   | 3 | 1 | 1   |

图中“+”号标识的就是点 $(x_i, f_i)(i = 0, \dots, 4)$ . 可以看出用直线拟合比较合适。

因此设 $\varphi_0(x) = 1, \varphi_1(x) = x, S_1(x) = a_0\varphi_0(x) + a_1\varphi_1(x) = a_0 + a_1x$ .


记 $\varphi_0 = (1, 1, 1, 1, 1)^T, \varphi_1 = (1, 2, 3, 4, 5)^T, \mathbf{f} = (4, 4.5, 6, 8, 8.5)^T$ , 则

$$\begin{aligned}(\varphi_0, \varphi_0) &= \sum_{i=0}^4 \omega_i = 8, (\varphi_0, \varphi_1) = (\varphi_1, \varphi_0) = \sum_{i=0}^4 \omega_i x_i = 22, (\varphi_1, \varphi_1) = \sum_{i=0}^4 \omega_i x_i^2 = 74; \\(\varphi_0, \mathbf{f}) &= \sum_{i=0}^4 \omega_i f_i = 47, (\varphi_1, \mathbf{f}) = \sum_{i=0}^4 \omega_i x_i f_i = 145.5.\end{aligned}$$

法方程为：

$$\begin{pmatrix} 8 & 22 \\ 22 & 74 \end{pmatrix} \begin{pmatrix} a_0 \\ a_1 \end{pmatrix} = \begin{pmatrix} 47 \\ 145.5 \end{pmatrix} \Rightarrow \begin{cases} a_0^* = 2.5648 \\ a_1^* = 1.2037 \end{cases} \Rightarrow S_1^*(x) = 2.5648 + 1.2037x.$$

## 曲线拟合问题举例一（续）



## 曲线拟合问题举例二

再看一个不是直线模型的例子。  
例、给定实验数据


|             |       |       |       |       |       |
|-------------|-------|-------|-------|-------|-------|
| $x_i$       | 1.00  | 1.25  | 1.50  | 1.75  | 2.00  |
| $y_i$       | 5.10  | 5.79  | 6.53  | 7.45  | 8.46  |
| $\bar{y}_i$ | 1.629 | 1.756 | 1.876 | 2.008 | 2.135 |

从实验数据来看，用指数模型 $y = ae^{bx}$  ( $a, b$ 待定)更合适，但是在具体计算时，必须用基函数线性表示，因此需要转为线性形式。

$$y = ae^{bx} \Rightarrow \ln y = \ln a + bx \Rightarrow \bar{y} = A + bx, \quad \bar{y} \stackrel{\text{def}}{=} \ln y, A \stackrel{\text{def}}{=} \ln a.$$

用直线 $\bar{y} = A + bx$ 拟合完数据 $x, \bar{y}$ 后，还原系数 $a$ ，从而得到指数形式的拟合曲线 $y = ae^{bx}$ 。这就是本题的求解思路。

## 曲线拟合问题举例二（续）



## 用正交多项式作最小二乘拟合

若用正交多项式 $\{p_k(x)\}_{k=0}^n$ 为基进行拟合, 则可以完全避免 $G$ 病态的问题。

设给定实验数据 $(x_i, y_i) (i = 0, \dots, m)$ , 权函数 $\omega(x)$ .

记 $\mathbf{p}_k = (p_k(x_0), \dots, p_k(x_m))^T$ ,  $\mathbf{y} = (y_0, \dots, y_m)^T$ ,  $\mathbf{a}^* = (a_0^*, \dots, a_n^*)^T$ , 其中

$$(\mathbf{p}_k, \mathbf{p}_l) = \sum_{i=0}^m \omega(x_i) p_k(x_i) p_l(x_i) = \begin{cases} 0, & l \neq k; \\ A_k \neq 0, & l = k. \end{cases}$$

则由以上正交性可知法方程 $G\mathbf{a} = \mathbf{d}$ 化为

$$\begin{pmatrix} (\mathbf{p}_0, \mathbf{p}_0) & & \\ & \ddots & \\ & & (\mathbf{p}_n, \mathbf{p}_n) \end{pmatrix} \begin{pmatrix} a_0 \\ \vdots \\ a_n \end{pmatrix} = \begin{pmatrix} (\mathbf{y}, \mathbf{p}_0) \\ \vdots \\ (\mathbf{y}, \mathbf{p}_n) \end{pmatrix}$$

## 用正交多项式作最小二乘拟合（续）

由以上方程组立得（实际计算时可以不产生法方程！）

$$a_k^* = \frac{(\mathbf{y}, \mathbf{p}_k)}{(\mathbf{p}_k, \mathbf{p}_k)}, \quad k = 0, \dots, n.$$

从而可得 $S^*(x)$ 的表达式。其平方误差为

$$\|\delta\|_2^2 = \|\mathbf{y}\|_2^2 - \sum_{k=0}^n A_k (a_k^*)^2.$$

但是需要注意的是：这些正交多项式应该是在离散内积意义下的正交多项式，以下给出离散内积意义下的多项式正交化过程，我们使用短递推过程。

## 离散内积下的多项式正交化过程

与连续内积下的多项式正交化过程类似，以下直接给出离散内积下的多项式的短递推正交化过程：

$$\begin{cases} p_0(x) = 1, p_{-1}(x) \stackrel{\text{def}}{=} 0, \\ p_{k+1}(x) = (x - \alpha_k)p_k(x) - \beta_k p_{k-1}(x), \quad k = 0, 1, \dots, n-1. \end{cases}$$

其中

$$\begin{cases} \alpha_k = \frac{(X \mathbf{p}_k, \mathbf{p}_k)}{(\mathbf{p}_k, \mathbf{p}_k)}, & k = 0, 1, \dots, n-1; \\ \beta_0 \stackrel{\text{def}}{=} 0, \beta_k = \frac{(\mathbf{p}_k, \mathbf{p}_k)}{(\mathbf{p}_{k-1}, \mathbf{p}_{k-1})}, & k = 1, \dots, n-1. \end{cases}$$

$$X = \text{daig}(x_0, \dots, x_m), \mathbf{p}_k = (p_k(x_0), \dots, p_k(x_m))^T, k = 0, 1, \dots, n.$$

